最小二乘法中拟合值与残差的正交性

1 模型是什么？

假设我们有 n 个样本点 (X_i, Y_i)，我们认为它们大致满足一条直线：

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

其中 u_i 是随机误差。我们想用**最小二乘法 (OLS)** 估计 β_0 和 β_1，得到 $\hat{\beta}_0, \hat{\beta}_1$。

拟合值（估计值）：

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

残差：

$$e_i = Y_i - \hat{Y}_i$$

2 正规方程从哪里来？

最小二乘法要最小化残差平方和：

$$Q = \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

为了找到使 Q 最小的 $\hat{\beta}_0$ 和 $\hat{\beta}_1$，我们分别对它们求导，并令导数等于 0。

对 $\hat{\beta}_0$ 求导（注意这里是对 $\hat{\beta}_0$ 求导，Y_i，X_i 是已知数据）：

$$\frac{\partial Q}{\partial \hat{\beta}_0} = \sum_{i=1}^{n} 2(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) \cdot (-1) = -2 \sum_{i=1}^{n} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = -2 \sum_{i=1}^{n} e_i = 0$$

所以：

$$\sum_{i=1}^{n} e_i = 0 \quad (\text{方程1})$$

这个方程的意思：**残差的总和等于 0**。

对 $\hat{\beta}_1$ 求导：

$$\frac{\partial Q}{\partial \hat{\beta}_1} = \sum_{i=1}^{n} 2(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) \cdot (-X_i) = -2 \sum_{i=1}^{n} X_i e_i = 0$$

所以：

$$\sum_{i=1}^{n} X_i e_i = 0 \quad (\text{方程2})$$

这个方程的意思：**残差与 X_i 的乘积之和等于 0**，即 X_i 与 e_i 正交（不相关）。

这两个方程就是一元回归的**正规方程**。它们是由最小二乘法的“一阶条件”自然推导出来的。

3 证明 $\hat{Y}_i$ 与 e_i 的协方差为 0

样本协方差的公式是：

$$\mathrm{Cov}(\hat{Y}_i, e_i) = \frac{1}{n}\sum_{i=1}^{n}(\hat{Y}_i - \bar{\hat{Y}})(e_i - \bar{e})$$

其中 $\bar{\hat{Y}} = \frac{1}{n}\sum \hat{Y}_i$，$\bar{e} = \frac{1}{n}\sum e_i$。

由方程 (1) 知道 $\sum e_i = 0$，所以 $\bar{e} = 0$。代入：

$$\mathrm{Cov}(\hat{Y}_i, e_i) = \frac{1}{n}\sum_{i=1}^{n}(\hat{Y}_i - \bar{\hat{Y}})e_i = \frac{1}{n}\left(\sum_{i=1}^{n}\hat{Y}_i e_i - \bar{\hat{Y}}\sum_{i=1}^{n} e_i\right)$$

又因为 $\sum e_i = 0$，所以：

$$\mathrm{Cov}(\hat{Y}_i, e_i) = \frac{1}{n}\sum_{i=1}^{n}\hat{Y}_i e_i$$

现在计算 $\sum \hat{Y}_i e_i$。把 $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ 代入：

$$\sum_{i=1}^{n}\hat{Y}_i e_i = \sum_{i=1}^{n}(\hat{\beta}_0 + \hat{\beta}_1 X_i)e_i = \hat{\beta}_0\sum_{i=1}^{n} e_i + \hat{\beta}_1\sum_{i=1}^{n} X_i e_i$$

由方程 (1) 得 $\sum e_i = 0$，由方程 (2) 得 $\sum X_i e_i = 0$。所以：

$$\sum \hat{Y}_i e_i = \hat{\beta}_0 \cdot 0 + \hat{\beta}_1 \cdot 0 = 0$$

因此：

$$\mathrm{Cov}(\hat{Y}_i, e_i) = \frac{1}{n}\cdot 0 = 0$$

4 结论

在普通最小二乘法中，**估计值 $\hat{Y}_i$ 与残差 e_i 的样本协方差为 0**，也就是它们不相关。这个结果不依赖于任何统计假设，是 OLS 的代数性质。

你之前看到的 X_{ji} 之类的符号只是把上面的 X_i 推广到多个自变量的情况，本质是一样的：每个自变量都与残差正交（$\sum X_{ji} e_i = 0$），所以估计值（自变量的线性组合）也与残差正交。