OLS估计量的统计性质——极详细推导

引言

本文以初学者能跟上的细致程度，推导普通最小二乘（OLS）估计量的三个核心性质：线性性、无偏性与有效性（方差最小）。每一步代数变形、每一个常数处理、每一个求和规则都给出解释。

1 超级基础的准备知识

1.1 模型设定

$$Y_i = \beta_1 + \beta_2 X_i + u_i, \quad i = 1, 2, \ldots, n$$

- Y_i：第i个观测的被解释变量。
- X_i：第i个观测的解释变量（固定）。
- β_1, β_2：未知的真实总体参数。
- u_i：随机误差项。
- n：样本容量。

1.2 均值与离差

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$
$$x_i = X_i - \bar{X}$$

离差的重要性质：

$$\sum_{i=1}^{n} x_i = \sum_{i=1}^{n}(X_i - \bar{X}) = \sum_{i=1}^{n} X_i - n\bar{X} = n\bar{X} - n\bar{X} = 0.$$

1.3 求和符号的简单规则

1. $\sum(a_i + b_i) = \sum a_i + \sum b_i$
2. $\sum(c \cdot a_i) = c \cdot \sum a_i$ （常数c可提出）
3. $\sum_{i=1}^{n} c = n \cdot c$

1.4 OLS估计量公式

最小二乘法通过最小化残差平方和 $\sum_{i=1}^{n}(Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i)^2$ 得到：

$$\hat{\beta}_2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{\sum x_i y_i}{\sum x_i^2} \tag{1}$$

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X} \tag{2}$$

其中 $y_i = Y_i - \bar{Y}$。

2 性质一：线性性

目标：证明 $\hat{\beta}_1$ 和 $\hat{\beta}_2$ 均可表示为 Y_i 的线性组合，系数仅由 X 决定。

2.1 $\hat{\beta}_2$ 的线性表示

由式(1)：

$$\hat{\beta}_2 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}.$$

分母 $D = \sum x_i^2$ 是常数（因X固定）。分子展开：

$$\begin{aligned}
\sum_{i=1}^{n} x_i y_i &= \sum_{i=1}^{n} x_i (Y_i - \bar{Y}) \\
&= \sum_{i=1}^{n} (x_i Y_i - x_i \bar{Y}) \\
&= \sum_{i=1}^{n} x_i Y_i - \bar{Y} \sum_{i=1}^{n} x_i.
\end{aligned}$$

由于 $\sum x_i = 0$，第二项消失，得到：

$$\sum_{i=1}^{n} x_i y_i = \sum_{i=1}^{n} x_i Y_i.$$

代入原式：

$$\hat{\beta}_2 = \frac{\sum_{i=1}^{n} x_i Y_i}{\sum_{i=1}^{n} x_i^2} = \sum_{i=1}^{n} \left(\frac{x_i}{\sum_{j=1}^{n} x_j^2} \right) Y_i.$$

定义权重：

$$k_i = \frac{x_i}{\sum_{j=1}^{n} x_j^2},$$

则

$$\hat{\beta}_2 = \sum_{i=1}^{n} k_i Y_i.$$

因为 x_i 固定，k_i 均为常数，故 $\hat{\beta}_2$ 是 Y_i 的线性组合。**线性性得证。**

2.2 权重 k_i 的两个重要性质

$$\sum_{i=1}^{n} k_i = \frac{1}{\sum x_j^2} \sum_{i=1}^{n} x_i = 0 \tag{3}$$

$$\sum_{i=1}^{n} k_i X_i = \sum_{i=1}^{n} k_i (x_i + \bar{X}) = \sum_{i=1}^{n} k_i x_i + \bar{X} \sum_{i=1}^{n} k_i = 1 \tag{4}$$

式(4) 中用到 $\sum k_i x_i = \sum \frac{x_i^2}{\sum x_j^2} = 1$。

2.3 $\hat{\beta}_1$ 的线性表示

由式(2)：

$$\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X} = \sum_{i=1}^{n} \frac{1}{n} Y_i - \bar{X} \sum_{i=1}^{n} k_i Y_i = \sum_{i=1}^{n} \left(\frac{1}{n} - \bar{X} k_i \right) Y_i.$$

令 $w_i = \frac{1}{n} - \bar{X} k_i$，则 $\hat{\beta}_1 = \sum_{i=1}^{n} w_i Y_i$，同样为 Y_i 的线性组合。

3 性质二：无偏性

目标：证明 $E(\hat{\beta}_1) = \beta_1$，$E(\hat{\beta}_2) = \beta_2$。

关键假定：

1. X_i 固定，从而 x_i, k_i 均固定。

2. $E(u_i) = 0$ 对所有 i。

3.1 $\hat{\beta}_2$ 的无偏性

将真实模型 $Y_i = \beta_1 + \beta_2 X_i + u_i$ 代入线性表示：

$$\begin{aligned}
\hat{\beta}_2 &= \sum_{i=1}^{n} k_i(\beta_1 + \beta_2 X_i + u_i) \\
&= \beta_1 \underbrace{\sum_{i=1}^{n} k_i}_{=0\ (\text{式}3)} + \beta_2 \underbrace{\sum_{i=1}^{n} k_i X_i}_{=1\ (\text{式}4)} + \sum_{i=1}^{n} k_i u_i \\
&= \beta_2 + \sum_{i=1}^{n} k_i u_i.
\end{aligned}$$

两边取数学期望：

$$E(\hat{\beta}_2) = \beta_2 + \sum_{i=1}^{n} k_i E(u_i) = \beta_2 + 0 = \beta_2.$$

因此 $\hat{\beta}_2$ 是 β_2 的无偏估计。

3.2 $\hat{\beta}_1$ 的无偏性

首先计算 $E(\bar{Y})$：

$$\bar{Y} = \frac{1}{n}\sum_{i=1}^{n}(\beta_1 + \beta_2 X_i + u_i) = \beta_1 + \beta_2 \bar{X} + \frac{1}{n}\sum_{i=1}^{n} u_i,$$

故

$$E(\bar{Y}) = \beta_1 + \beta_2 \bar{X} + \frac{1}{n}\sum E(u_i) = \beta_1 + \beta_2 \bar{X}.$$

再由 $\hat{\beta}_1 = \bar{Y} - \hat{\beta}_2 \bar{X}$ 取期望：

$$E(\hat{\beta}_1) = E(\bar{Y}) - \bar{X}E(\hat{\beta}_2) = (\beta_1 + \beta_2 \bar{X}) - \bar{X}\beta_2 = \beta_1.$$

故 $\hat{\beta}_1$ 也是无偏的。

4 性质三：方差与有效性

4.1 补充假定

3. 同方差：$\mathrm{Var}(u_i) = E(u_i^2) = \sigma^2$（常数）。

4. 无自相关：$\mathrm{Cov}(u_i, u_j) = E(u_i u_j) = 0$ 对 $i \neq j$。

4.2 方差运算规则

若 $E(X) = 0$，则 $\mathrm{Var}(X) = E(X^2)$。对常数 a，$\mathrm{Var}(aX) = a^2\mathrm{Var}(X)$。不相关变量之和的方差等于方差之和。

4.3 $\hat{\beta}_2$ 的方差

由 $\hat{\beta}_2 - \beta_2 = \sum k_i u_i$，且 $E(\hat{\beta}_2) = \beta_2$：

$$\begin{aligned}
\mathrm{Var}(\hat{\beta}_2) &= E\left[\left(\sum_{i=1}^{n} k_i u_i\right)^2\right] \\
&= E\left[\sum_{i=1}^{n} k_i^2 u_i^2 + 2\sum_{i<j} k_i k_j u_i u_j\right] \\
&= \sum_{i=1}^{n} k_i^2 E(u_i^2) + 2\sum_{i<j} k_i k_j E(u_i u_j) \\
&= \sum_{i=1}^{n} k_i^2 \sigma^2 + 0 = \sigma^2 \sum_{i=1}^{n} k_i^2.
\end{aligned}$$

计算 $\sum k_i^2$：

$$\sum_{i=1}^{n} k_i^2 = \sum_{i=1}^{n} \frac{x_i^2}{(\sum x_j^2)^2} = \frac{\sum x_i^2}{(\sum x_i^2)^2} = \frac{1}{\sum x_i^2}.$$

于是

$$\boxed{\mathrm{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum_{i=1}^{n} x_i^2}}.$$

4.4 $\hat{\beta}_1$ 的方差

由 $\hat{\beta}_1 = \sum w_i Y_i$，代入真实模型可证 $\hat{\beta}_1 - \beta_1 = \sum w_i u_i$（过程略，需计算 $\sum w_i = 1$ 和 $\sum w_i X_i = 0$）。于是

$$\mathrm{Var}(\hat{\beta}_1) = \sigma^2 \sum_{i=1}^{n} w_i^2.$$

计算 $\sum w_i^2$：

$$w_i = \frac{1}{n} - \bar{X}k_i, \quad w_i^2 = \frac{1}{n^2} - \frac{2\bar{X}}{n}k_i + \bar{X}^2 k_i^2.$$

求和并利用 $\sum k_i = 0$，$\sum k_i^2 = \frac{1}{\sum x_i^2}$：

$$\sum_{i=1}^{n} w_i^2 = \frac{n}{n^2} - \frac{2\bar{X}}{n} \cdot 0 + \bar{X}^2 \cdot \frac{1}{\sum x_i^2} = \frac{1}{n} + \frac{\bar{X}^2}{\sum x_i^2}.$$

因此

$$\boxed{\mathrm{Var}(\hat{\beta}_1) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum x_i^2} \right)}.$$

等价形式（利用 $\sum X_i^2 = \sum x_i^2 + n\bar{X}^2$）：

$$\mathrm{Var}(\hat{\beta}_1) = \sigma^2 \frac{\sum X_i^2}{n \sum x_i^2}.$$

4.5 有效性（高斯-马尔可夫定理）

在满足上述假定时，OLS估计量 $\hat{\beta}_1$ 和 $\hat{\beta}_2$ 是**最佳线性无偏估计量（BLUE）**：在所有关于 β_1, β_2 的线性无偏估计量中，它们的方差最小。

5 误差方差 σ^2 的估计与标准误

σ^2 未知，需用样本估计。残差 $e_i = Y_i - \hat{\beta}_1 - \hat{\beta}_2 X_i$。无偏估计量为：

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n} e_i^2}{n-2}.$$

自由度 $n-2$ 是因为估计两个参数消耗了两个自由度。

5.1 标准误

用 $\hat{\sigma}$ 替代 σ 得到估计量的标准误（方差的平方根）：

$$\mathrm{SE}(\hat{\beta}_2) = \frac{\hat{\sigma}}{\sqrt{\sum x_i^2}},$$

$$\mathrm{SE}(\hat{\beta}_1) = \hat{\sigma}\sqrt{\frac{1}{n} + \frac{\bar{X}^2}{\sum x_i^2}}.$$

总结

- **线性性**：OLS估计量是 Y_i 的加权和，权数仅依赖于 X。
- **无偏性**：估计量的期望等于总体真值，平均而言没有系统偏差。
- **有效性**：OLS在所有线性无偏估计中波动最小（方差最小）。
- **方差公式**：解释变量波动 $\sum x_i^2$ 越大、样本量 n 越大、误差方差 σ^2 越小，估计越精确。