拟合优度的度量——可决系数 R^2 的详细讲解

第一步：我们要解决什么问题？（引入概念）

想象一下，我们在纸上画了很多散点（代表数据），然后我们画了一条直线试图穿过这些点。这条直线就是我们的“样本回归线”，它代表了我们对数据关系的一种猜测或“拟合”。

- **拟合**：就是画一条线来代表这些散点的趋势。
- **拟合优度**：这条线画得好不好？它和真实的点靠得有多近？这就是“拟合优度”要回答的问题。

为了用数字来衡量“好”的程度，我们需要一把尺子。这把尺子就是**可决系数**（R^2）。而要理解这把尺子，我们必须先学会把数据的波动（变差）拆开来分析。

第二步：总变差的分解—— 把数据的波动拆开来看

我们先看一个核心公式（基于样本回归函数）：

$$Y_i = \hat{Y}_i + e_i \tag{1}$$

别被符号吓到，我们来解释每一个字母：

- Y_i：**真实的观测值**。比如，第 i 个家庭真正花了多少钱。这是图上的那个**实心圆点**的高度。
- $\hat{Y}_i$：**估计值（预测值）**。这是我们画的回归线在第 i 个点位置上的高度，也就是线**预测**这个家庭应该花多少钱。
- e_i：**残差**。就是真实值 Y_i 和预测值 $\hat{Y}_i$ 之间的距离差（$e_i = Y_i - \hat{Y}_i$）。如果线画得完美，这个差就是 0。

2.1 引入一个参考标准：平均值 $\bar{Y}$

光看每个点离回归线多远还不够，我们需要一个比较的**基准**。这个基准就是所有真实值 Y_i 的**平均值** $\bar{Y}$。

想象一个场景：你猜一个人的身高。

- 如果没有任何信息（比如不知道体重），你猜的平均身高 $\bar{Y}$ 就是最稳妥的猜测。
- 现在，你知道了体重 X，你用回归线算出了一个更精准的猜测 $\hat{Y}_i$。
- 我们要看的是：**用了体重信息（回归线）之后，你的猜测比瞎猜（用平均值）好了多少？**

2.2 关键的离差恒等式推导（极其详细，无跳步）

我们要比较三个距离：

(1) **总离差**：真实值 Y_i 离开平均值 $\bar{Y}$ 有多远？即 $(Y_i - \bar{Y})$。

(2) **解释离差**：回归线预测值 $\hat{Y}_i$ 离开平均值 $\bar{Y}$ 有多远？即 $(\hat{Y}_i - \bar{Y})$。

(3) **未解释离差**：真实值 Y_i 离开回归线预测值 $\hat{Y}_i$ 有多远？即 $(Y_i - \hat{Y}_i) = e_i$。

推导开始：

我们已知回归线方程：$Y_i = \hat{Y}_i + e_i$。

步骤 1：等式两边同时减去平均值 $\bar{Y}$。

$$Y_i - \bar{Y} = \hat{Y}_i + e_i - \bar{Y}$$

步骤 2：把右边稍微重新排列一下，把 $\hat{Y}_i$ 和 $-\bar{Y}$ 放在一起。

$$Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + e_i \tag{2}$$

结论：这告诉我们，**总离差** 刚好等于 **回归线解释了的离差** 加上 **回归线没解释的残差**。

- 如果回归线完全没用（$\hat{Y}_i = \bar{Y}$），那么解释离差为 0，总离差全是残差。
- 如果回归线完美（$e_i = 0$），那么总离差全被解释了。

2.3 为什么要把离差平方再加总？（$\mathrm{TSS} = \mathrm{ESS} + \mathrm{RSS}$）

前面我们只看了**一个点**的情况。现在我们要看**所有点**的整体情况。

但是，直接加总离差 $(Y_i - \bar{Y})$ 会有一个致命问题：有的点比平均值高（正数），有的比平均值低（负数），一加就抵消了，总和接近 0，看不出波动大小。

解决办法：**平方！** 平方之后负数变正数，越远的点贡献越大。

我们对刚才的离差等式两边进行**平方，然后对所有的 i（从 1 到 n 个样本）求和。**

等式： $(Y_i - \bar{Y}) = (\hat{Y}_i - \bar{Y}) + e_i$

两边平方：

$$(Y_i - \bar{Y})^2 = [(\hat{Y}_i - \bar{Y}) + e_i]^2$$

展开右边（完全平方公式 $(a+b)^2 = a^2 + 2ab + b^2$）：

$$(Y_i - \bar{Y})^2 = (\hat{Y}_i - \bar{Y})^2 + 2(\hat{Y}_i - \bar{Y})e_i + e_i^2$$

对所有样本求和（$\sum_{i=1}^{n}$）：

$$\sum(Y_i - \bar{Y})^2 = \sum(\hat{Y}_i - \bar{Y})^2 + 2\sum(\hat{Y}_i - \bar{Y})e_i + \sum e_i^2$$

关键跳跃点解释（这里绝对不停留）： 在最小二乘法（OLS）的假设下，中间项 $2\sum(\hat{Y}_i - \bar{Y})e_i$ **恰好等于 0**。（因为残差和预测值的协方差为 0，这是 OLS 的数学性质，对于初学者只要记住：画回归线的方法保证了这一项消掉了）。

最终简化结果：

$$\sum(Y_i - \bar{Y})^2 = \sum(\hat{Y}_i - \bar{Y})^2 + \sum e_i^2 \tag{3}$$

这就是 **式 (2.47)** 和 **(2.48)** 的来历。用简洁的代号表示就是：

$$\text{TSS} = \text{ESS} + \text{RSS} \tag{4}$$

- **TSS (Total Sum of Squares)**：总离差平方和。代表 Y 原本的波动有多大。
- **ESS (Explained Sum of Squares)**：回归平方和。代表**回归线能解释**的波动有多大。
- **RSS (Residual Sum of Squares)**：残差平方和。代表**回归线解释不了**的波动有多大。

第三步：可决系数 R^2 —— 一把衡量好坏的尺子

现在我们有了 TSS、ESS、RSS。我们想看回归线“解释了的波动”占总波动的**比例**。

3.1 公式推导

既然 $\text{TSS} = \text{ESS} + \text{RSS}$，我们两边同时除以 TSS（假设 TSS 不为 0）：

$$\frac{\text{TSS}}{\text{TSS}} = \frac{\text{ESS}}{\text{TSS}} + \frac{\text{RSS}}{\text{TSS}}$$

$$1 = \frac{\text{ESS}}{\text{TSS}} + \frac{\text{RSS}}{\text{TSS}}$$

我们定义 **可决系数** R^2 为 $\frac{\text{ESS}}{\text{TSS}}$。把它移项一下：

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}} \tag{5}$$

3.2 直观理解 R^2 的大小意味着什么？

- **情况 1：拟合极好（$R^2 = 0.99$）**
  这意味着 $R^2 = 0.99$，也就是 $\frac{\text{ESS}}{\text{TSS}} = 0.99$。

解释：总波动中，有 99% 是因为 X 的变化引起的（被回归线抓住了），只有 1% 是乱七八糟的噪声（残差）。
结论： 线画得特别好，点几乎都贴在线上。

- **情况 2：拟合极差（$R^2 = 0.01$）**
  这意味着 $\frac{\text{RSS}}{\text{TSS}} \approx 0.99$。
  解释：总波动中，只有 1% 被 X 解释，剩下的 99% 都不知道哪来的（全在残差里）。
  结论： 这条线画了等于没画，还不如直接画一条平均值线。

- **情况 3：取值范围**
  因为 ESS 最大等于 TSS（完美拟合），最小等于 0（完全没用）。
  所以 R^2 永远在 **0 到 1** 之间。它不会出现负数（在带截距项的 OLS 回归中）。

3.3 书上的计算例子（一步步算）

书里给了一个例子数据，虽然我们没看到表 2.4 的全貌，但给了两个关键结果：

- 残差平方和 $\text{RSS} = \sum e_i^2 = 46116.02$
- 总平方和 $\text{TSS} = \sum y_i^2 = 7561992$

我们代入公式 $R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}$：
步骤 1： 算除法 $\frac{46116.02}{7561992} \approx 0.006098$（约等于千分之六）。
步骤 2： 用 1 减去它 $1 - 0.006098 = 0.993902$。
步骤 3： 化为百分数 99.39%。
这就像一个考试，满分 100 分，你只扣了 0.6 分，考了 99.4 分。非常棒！

第四步：可决系数 R^2 与相关系数 r 的关系（极其详细的代数推导）

这是最容易混淆的地方。书上说“在一元线性回归中，$R^2 = r^2$”。我们不仅要记住这句话，还要看懂是怎么变出来的。

4.1 先回忆相关系数 r 的公式

$$r = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - \bar{X})^2 \sum(Y_i - \bar{Y})^2}} \tag{6}$$

（为了书写方便，我们记分子为 $\sum xy$，分母为 $\sqrt{\sum x^2 \sum y^2}$）

4.2 推导 R^2 的另一副面孔

我们已经知道 $R^2 = \frac{\text{ESS}}{\text{TSS}} = \frac{\sum(\hat{Y}_i - \bar{Y})^2}{\sum(Y_i - \bar{Y})^2}$。

关键的一步是处理分子 ESS。在一元回归中，我们知道回归线的斜率 $\hat{\beta}_2$ 的公式是：

$$\hat{\beta}_2 = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2} \tag{7}$$

另外，根据回归线的性质，预测值 $\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_i$，且有 $\hat{Y}_i - \bar{Y} = \hat{\beta}_2(X_i - \bar{X})$。（**暂停理解一下：** 回归线经过中心点 $(\bar{X}, \bar{Y})$，所以预测值偏离平均值的幅度，等于斜率 $\hat{\beta}_2$ 乘以 X 偏离其平均值的幅度。）

现在我们来化简 ESS（分子）：

$$\text{ESS} = \sum(\hat{Y}_i - \bar{Y})^2$$

把 $\hat{Y}_i - \bar{Y} = \hat{\beta}_2(X_i - \bar{X})$ 代入：

$$\text{ESS} = \sum[\hat{\beta}_2(X_i - \bar{X})]^2$$

$$\text{ESS} = \sum \hat{\beta}_2^2(X_i - \bar{X})^2$$

常数 $\hat{\beta}_2^2$ 可以提到求和符号外面：

$$\text{ESS} = \hat{\beta}_2^2 \sum(X_i - \bar{X})^2$$

现在把 $\hat{\beta}_2$ 的公式代进去：

$$\text{ESS} = \left(\frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2}\right)^2 \times \sum(X_i - \bar{X})^2$$

注意看括号外面的指数。外面是平方，里面分母有 $\sum(X_i - \bar{X})^2$，分子有 $\sum(X_i - \bar{X})^2$ 的一次方。约分掉一个：

$$\text{ESS} = \frac{[\sum(X_i - \bar{X})(Y_i - \bar{Y})]^2}{\sum(X_i - \bar{X})^2} \tag{8}$$

4.3 最后一步：凑出 R^2 的样子

我们已经把分子 ESS 化简好了。现在看整个 R^2：

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = \frac{\frac{[\sum(X_i - \bar{X})(Y_i - \bar{Y})]^2}{\sum(X_i - \bar{X})^2}}{\sum(Y_i - \bar{Y})^2}$$

这等于：

$$R^2 = \frac{[\sum(X_i - \bar{X})(Y_i - \bar{Y})]^2}{\sum(X_i - \bar{X})^2 \cdot \sum(Y_i - \bar{Y})^2} \tag{9}$$

看看这个式子，它正好就是 **相关系数 r 的公式** 的 **平方**！因为：

$$r^2 = \left(\frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - \bar{X})^2 \sum(Y_i - \bar{Y})^2}}\right)^2 = \frac{[\sum(X_i - \bar{X})(Y_i - \bar{Y})]^2}{\sum(X_i - \bar{X})^2 \sum(Y_i - \bar{Y})^2} \tag{10}$$

结论： 在一元回归里，$R^2 = r^2$。

4.4 为什么它们概念不同？（这部分极其重要，防止用错）

虽然数值上平方一下就是对方，但它们的**灵魂**是完全不同的：

对比项	可决系数 R^2	相关系数 r
方向性	有方向的因果关系。比如 X 是原因，Y 是结果。R^2 衡量的是 X 解释了 Y 变动的百分之几。	无方向的相互依存关系。X 和 Y 一起变，变动的紧密程度如何。
正负号	永远非负 $0 \leq R^2 \leq 1$。因为它衡量的是比例（面积/面积）。	可正可负 $-1 \leq r \leq 1$。正号表示同向变化，负号表示反向变化。
比喻	用身高（X）去预测体重（Y），身高能解释体重变动的 70%。你**不会**反过来说体重解释身高变动的 70%。	身高和体重的关联度是 0.8。这是一个对称的数值，不分谁解释谁。

总结

整篇文章的逻辑链条如下：

1. **拆开波动**：把每个点的差距拆成“回归线解释的”和“没解释的”。
2. **平方求和**：为了避免正负抵消，平方后求和得到 $\text{TSS} = \text{ESS} + \text{RSS}$。
3. **计算比例**：看 ESS 占 TSS 的多少，这就是 R^2。
4. **对比概念**：在一元情况下，R^2 正好等于相关系数 r 的平方，但理解上一个是因果解释程度，一个是相互关联程度。

希望这样的讲解能够让你完全明白每一步是在做什么。