回归系数的假设检验与区间估计——细致讲解

第一步：我们为什么需要“假设检验”和“区间估计”？

想象一个场景：你想研究“家庭月收入”对“家庭月消费”的影响。你收集了10个家庭的数据，用最小二乘法（OLS）算出了一条回归直线：

$$\text{消费} = 266.38 + 0.604 \times \text{收入}$$

这里 0.604 就是斜率系数 $\hat{\beta}_2$ 的估计值。它意味着：收入每增加1元，消费平均增加约0.604元。

但问题来了：

1. 这个0.604是**真实**的影响吗？还是因为**抽样误差**偶然得到的？（比如换另一组10个家庭，算出来可能是0.58或0.62）
2. 真实的 β_2 会不会其实是 0？如果真实是0，那就意味着**收入对消费根本没影响**，我们的0.604只是抽样的假象。

假设检验就是为了回答第一个问题：这个估计值是否足够“显著”地不为零（或不为某个特定值）。
区间估计则是为了回答：真实的 β_2 大概落在什么范围内（比如0.565到0.642之间）。

第二步：OLS估计量 $\hat{\beta}_1$ 和 $\hat{\beta}_2$ 的分布性质（这是所有推断的基础）

2.1 为什么它们是随机变量？

因为我们用的是**样本**数据，每次抽样得到的数据不一样，算出来的 $\hat{\beta}_1$ 和 $\hat{\beta}_2$ 就不一样。所以它们都是**随机变量**，有自己的概率分布。

2.2 它们服从什么分布？

在经典线性回归假设下，我们假定误差项 u_i 服从正态分布。因为 $Y_i = \beta_1 + \beta_2 X_i + u_i$，所以 Y_i 也服从正态分布。之前我们已经证明过，$\hat{\beta}_1$ 和 $\hat{\beta}_2$ 都是 Y_i 的线性组合（线性函数），而正态随机变量的线性组合仍然服从正态分布。

因此，即使样本很小，$\hat{\beta}_1$ 和 $\hat{\beta}_2$ **精确服从正态分布**。

（如果样本很大，即使误差项不是正态，根据中心极限定理，$\hat{\beta}$ 也会**趋近**正态分布。）

2.3 正态分布的参数是什么？

一个正态分布由两个参数决定：均值（期望）和方差。

我们已经证明过：

- $\hat{\beta}_1$ 和 $\hat{\beta}_2$ 是**无偏估计量**，即 $E(\hat{\beta}_1) = \beta_1$，$E(\hat{\beta}_2) = \beta_2$。所以分布的**中心**就是真实参数值。
- 它们的方差公式也已经推导过（这里不重复推导，直接用结论）：

$$\mathrm{Var}(\hat{\beta}_1) = \sigma^2 \cdot \frac{\sum X_i^2}{n \sum x_i^2}$$

$$\mathrm{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_i^2}$$

其中 $\sum x_i^2 = \sum (X_i - \bar{X})^2$，$\sigma^2$ 是误差项 u_i 的方差。

于是，它们的分布可写成：

$$\hat{\beta}_1 \sim N\left(\beta_1, \sigma^2 \cdot \frac{\sum X_i^2}{n \sum x_i^2}\right)$$

$$\hat{\beta}_2 \sim N\left(\beta_2, \frac{\sigma^2}{\sum x_i^2}\right)$$

关键点：这两个分布的中心是真实参数，离散程度由误差方差 σ^2 和样本数据决定。

第三步：标准化变换——从正态到标准正态

为了做统计推断，我们通常把一般的正态变量转换成**标准正态变量** z，方法是：

$$z = \frac{\text{随机变量} - \text{其期望}}{\text{其标准差}}$$

这个变换后的 z 服从标准正态分布 $N(0,1)$（均值为0，方差为1）。

对 $\hat{\beta}_2$ 做这个变换：

- 随机变量：$\hat{\beta}_2$
- 期望：β_2
- 标准差：$\mathrm{SE}(\hat{\beta}_2) = \sqrt{\mathrm{Var}(\hat{\beta}_2)} = \frac{\sigma}{\sqrt{\sum x_i^2}}$

于是得到：

$$z = \frac{\hat{\beta}_2 - \beta_2}{\mathrm{SE}(\hat{\beta}_2)} = \frac{\hat{\beta}_2 - \beta_2}{\sigma / \sqrt{\sum x_i^2}} \sim N(0,1)$$

同理，对 $\hat{\beta}_1$ 也有类似结果。

第四步：现实中的麻烦——σ^2 未知怎么办？

注意，上面那个 z 公式的分母里有 σ，它是**总体**误差的方差。现实中我们根本不知道 σ 的真实值，只能从样本去**估计**它。

我们用残差 $e_i = Y_i - \hat{Y}_i$ 来估计误差，得到 σ^2 的无偏估计量：

$$\hat{\sigma}^2 = \frac{\sum e_i^2}{n-2}$$

（为什么除以 $n-2$？因为估计两个参数 β_1, β_2 用掉了两个自由度。）

然后，我们用这个估计值 $\hat{\sigma}^2$ 来代替真实的 σ^2，计算出**估计的标准误差**（注意名字变化了）：

$$\widehat{\mathrm{SE}}(\hat{\beta}_2) = \frac{\hat{\sigma}}{\sqrt{\sum x_i^2}}$$

这时候，如果我们还用这个估计的标准误差去做标准化：

$$t = \frac{\hat{\beta}_2 - \beta_2}{\widehat{\mathrm{SE}}(\hat{\beta}_2)}$$

这个比值还服从标准正态分布吗？

答案是：不服从了。 因为分母不再是一个常数，而是一个**随机变量**（$\hat{\sigma}$ 是随样本变化的）。

4.1 为什么变成了 t 分布？

严格证明需要数学推导，但直观理解是：

- 分子 $\hat{\beta}_2 - \beta_2$ 服从正态分布。
- 分母涉及 $\hat{\sigma}^2$，而 $\hat{\sigma}^2$ 与卡方分布有关。
- 一个正态随机变量除以一个独立的卡方随机变量（除以其自由度）的平方根，得到的比值服从 **学生氏 t 分布**。

在回归模型中，$\hat{\beta}_2$ 与 $\hat{\sigma}^2$ 是独立的，且 $\hat{\sigma}^2$ 的自由度是 $n-2$，所以：

$$t = \frac{\hat{\beta}_2 - \beta_2}{\widehat{\mathrm{SE}}(\hat{\beta}_2)} \sim t(n-2)$$

即自由度为 $n-2$ 的 t 分布。

注意：

- 如果样本量很大（$n \to \infty$），t 分布会趋近于标准正态分布。此时用 z 或 t 差别不大。
- 如果样本量小，必须用 t 分布，因为它的尾巴比正态分布厚，更保守，能反映用估计方差带来的额外不确定性。

第五步：回归系数的假设检验（核心实操）

5.1 检验的基本思路

我们想检验一个原假设（比如 $\beta_2 = 0$，即“X 对 Y 没有影响”）。如果这个假设是真的，那么从数据算出的 $\hat{\beta}_2$ 应该离0不远；如果离0很远，我们就怀疑原假设不成立。

具体做法：

1. 假设 $H_0 : \beta_2 = 0$ 为真。
2. 计算检验统计量：$t = \frac{\hat{\beta}_2 - 0}{\widehat{\mathrm{SE}}(\hat{\beta}_2)}$。
3. 看这个 t 值落在 t 分布的哪个位置。如果落在两端极端区域（小概率事件发生），就拒绝原假设。

5.2 双侧检验的步骤（以检验 $\beta_2 = 0$ 为例）

第一步：提出假设

- 原假设 $H_0 : \beta_2 = 0$
- 备择假设 $H_1 : \beta_2 \neq 0$

第二步：计算 t 统计量

- 用样本数据算出 $\hat{\beta}_2$ 和它的标准误差 $\widehat{\mathrm{SE}}(\hat{\beta}_2)$。
- 代入公式 $t = \frac{\hat{\beta}_2}{\widehat{\mathrm{SE}}(\hat{\beta}_2)}$。

第三步：确定显著性水平 α（通常取0.05或0.01）

- α 是我们愿意承担的“错误拒绝原假设”的最大风险。
- 对于双侧检验，我们在 t 分布左右两边各划出 $\alpha/2$ 的拒绝域。

第四步：查表得到临界值

- 自由度 $df = n - 2$。
- 比如 $n = 10$，$df = 8$，$\alpha = 0.05$，查 t 分布表得 $t_{0.025}(8) = 2.306$。
- 拒绝域是：$t < -2.306$ 或 $t > 2.306$。

第五步：比较决策

- 如果样本计算的 $|t| > 2.306$，则落在拒绝域，拒绝 H_0，认为 β_2 显著不为0。
- 如果 $|t| \leq 2.306$，则不拒绝 H_0，认为没有足够证据说 β_2 不为0。

5.3 例子演练（消费-收入数据）

已知：$\hat{\beta}_2 = 0.60366$，$\widehat{\mathrm{SE}}(\hat{\beta}_2) = 0.01672$，$n = 10$。

计算 t 值：

$$t = \frac{0.60366}{0.01672} = 36.1085$$

自由度 $df = 10 - 2 = 8$，临界值 $t_{0.025}(8) = 2.306$。

显然 36.1085 远大于 2.306，所以强烈拒绝 $H_0 : \beta_2 = 0$，认为收入对消费有显著影响。

5.4 显著性水平变化会导致结论变化吗？

例如：如果 $t = 2.5000$，$df = 18$。

- 当 $\alpha = 0.05$，临界值 2.1009，$|t| > 2.1009$，拒绝 H_0。
- 当 $\alpha = 0.01$，临界值 2.8784，$|t| < 2.8784$，不拒绝 H_0。

这说明：**结论依赖于你选的严格程度** α。α 越小，越不容易拒绝原假设。

5.5 更方便的方法：P 值检验

为了避免每次查表，软件通常给出 P 值。

定义：在 H_0 为真的条件下，观察到当前样本 t 统计量绝对值（或更极端情况）的概率。

- 对于双侧检验，P 值 $= P(|T| > |t_{\text{样本}}|)$。

决策规则：

- 如果 P 值 ¡ α，拒绝 H_0。
- 如果 P 值 ¿ α，不拒绝 H_0。

例如，前面 $t = 36.1085$ 对应的 P 值几乎是0.0000，远小于0.05，所以拒绝 H_0。

第六步：回归系数的区间估计（置信区间）

6.1 区间估计想干什么？

点估计（如 $\hat{\beta}_2 = 0.604$）只是单个数值，我们不知道它离真实值有多近。区间估计则是给出一个**范围**，并且说明这个范围包含真实值的概率（置信水平）。

公式形式：

$$\hat{\beta}_2 \pm \text{临界值} \times \widehat{\text{SE}}(\hat{\beta}_2)$$

6.2 小样本下（σ^2 未知）的置信区间推导

因为 $t = \frac{\hat{\beta}_2 - \beta_2}{\widehat{\text{SE}}(\hat{\beta}_2)} \sim t(n-2)$，

我们可以写出概率表达式：

$$P\left(-t_{\alpha/2} < \frac{\hat{\beta}_2 - \beta_2}{\widehat{\text{SE}}(\hat{\beta}_2)} < t_{\alpha/2}\right) = 1 - \alpha$$

其中 $t_{\alpha/2}$ 是自由度为 $n-2$ 的 t 分布双侧临界值。

把不等式变形，解出 β_2：

1. 乘以标准误差（正数，不等号方向不变）：

$$-t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2) < \hat{\beta}_2 - \beta_2 < t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2)$$

2. 各项减去 $\hat{\beta}_2$：

$$-\hat{\beta}_2 - t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2) < -\beta_2 < -\hat{\beta}_2 + t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2)$$

3. 乘以 -1（不等号反向）：

$$\hat{\beta}_2 + t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2) > \beta_2 > \hat{\beta}_2 - t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2)$$

4. 重新排列，得到熟悉的置信区间：

$$\hat{\beta}_2 - t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2) < \beta_2 < \hat{\beta}_2 + t_{\alpha/2} \cdot \widehat{\text{SE}}(\hat{\beta}_2)$$

因此，**置信水平为 $1-\alpha$ 的置信区间是：**

$$\left[\hat{\beta}_2 - t_{\alpha/2}(n-2) \cdot \widehat{\text{SE}}(\hat{\beta}_2), \quad \hat{\beta}_2 + t_{\alpha/2}(n-2) \cdot \widehat{\text{SE}}(\hat{\beta}_2)\right]$$

6.3 例子计算

消费-收入数据：$\hat{\beta}_2 = 0.60366$，$\widehat{\mathrm{SE}} = 0.01672$，$n = 10$，取 $\alpha = 0.05$。

- $df = 8$，$t_{0.025}(8) = 2.306$。
- 误差幅度 $= 2.306 \times 0.01672 = 0.03855$。
- 下限 $= 0.60366 - 0.03855 = 0.56511$。
- 上限 $= 0.60366 + 0.03855 = 0.64221$。

所以，β_2 的95%置信区间为 $[0.5651, 0.6422]$。

6.4 对置信区间的正确理解

- **不是**说“β_2 有95%的概率落在0.5651到0.6422之间”。真实 β_2 是一个固定但未知的常数，它要么在区间里，要么不在，概率只能是0或1。
- **正确解释**：如果我们重复抽样100次，每次按同样方法计算一个95%置信区间，那么大约有95个区间会包含真实的 β_2。我们手头的这个区间是这100次中的一次实现，我们有95%的信心说它盖住了真实值。

总结对照表

表 1: 不同情形下的推断方法对比

情形	方差 σ^2	样本量	统计量及其分布	用于假设检验	用于区间估计
理想情况	已知	任意	$z \sim N(0,1)$	查正态表	正态分位数
大样本	未知（用 $\hat{\sigma}^2$ 估计）	大	近似 $z \sim N(0,1)$	查正态表	正态分位数
小样本（最常见）	未知（用 $\hat{\sigma}^2$ 估计）	小	$t \sim t(n-2)$	查 t 表	t 分位数

通过以上极其细致的步骤，你应该能完全理解回归系数的假设检验和区间估计的来龙去脉，以及为什么在小样本中必须使用 t 分布。