

多元线性回归模型及古典假定

第一步：我们要解决什么问题？（从简单走向多元）

想象一下，你是一个小镇的市长，你想研究到底是什么影响了老百姓的消费支出（ Y ）。在简单线性回归里，我们只找了一个原因，比如“收入（ X ）”。我们画了一条线来拟合数据，这就是一元回归。但现实世界哪有这么简单？除了收入，难道“财富积累”、“年龄”、“预期未来收入”不会影响消费吗？如果我们就只盯着“收入”这一个因素，而把其他重要因素忽略了，这些被忽略的因素就会跑到“随机扰动项（ u ）”里去捣乱，导致我们的模型出现“设定误差”——也就是瞎建模。

所以，我们需要一种能同时把多个因素（ X ）都放进模型里的方法，这就叫多元线性回归模型。

第二步：多元线性回归模型的基本面貌（标量形式）

2.1 先看一个实例：如何把非线性的东西变成线性的？

书上举了一个非常有名的经济学函数：柯布-道格拉斯生产函数。

$$Y = AK^\alpha L^\beta u \quad (3.1)$$

别被字母吓到，我们来逐一拆解：

- Y ：总产出（比如一家工厂生产了多少东西）。
- K ：投入的资本（机器、厂房）。
- L ：投入的劳动力（工人数量）。
- A ：技术水平（一个常数基数）。
- α 和 β ：资本和劳动力的弹性（也就是 K 和 L 增加1%， Y 能增加百分之几）。
- u ：随机扰动项（不可控的因素，比如突然停电、工人生病）。

发现问题了吗？这里的 K 和 L 是带着指数 (α, β) 相乘的，这不是线性关系！我们没法直接用线性回归算。

解决办法：取自然对数 $(\ln)$ ！数学里有一条黄金法则：乘积变相加，指数变系数。我们对等式两边同时取自然对数：等式左边： $\ln(Y)$ 等式右边： $\ln(A \cdot K^\alpha \cdot L^\beta \cdot u)$

我们一步步拆开右边的对数（对数性质： $\ln(AB) = \ln A + \ln B$, $\ln(A^b) = b \ln A$ ）：

$$\ln Y = \ln A + \ln(K^\alpha) + \ln(L^\beta) + \ln u$$

$$\ln Y = \ln A + \alpha \ln K + \beta \ln L + \ln u$$

$$\ln Y = \ln A + \alpha \ln K + \beta \ln L + \ln u \quad (3.2)$$

这就是公式(3.2)！你看，现在变量变成了 $\ln K$ 和 $\ln L$ ，它们前面都是常数系数 (α, β) ，加号连接。这就变成了一个标准的二元线性回归模型！这个过程叫做**模型的线性化**。

2.2 多元总体线性回归函数的一般形式

有了上面的铺垫，我们写出包含 k 个解释变量的一般公式(3.5)：

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \cdots + \beta_k X_{ki} + u_i \quad (3.5)$$

每一个符号是什么意思？

- Y_i ：第 i 个观测值的被解释变量（比如第 i 个人的消费）。
- $X_{2i}, X_{3i}, \dots, X_{ki}$ ：第 i 个观测值的第2个、第3个……第 k 个解释变量（注意：下标的前面是变量编号，后面是样本编号）。
- β_1 ：截距项。就像基础消费，不管你收入多少，都得花这么多钱维持生存。
- $\beta_2, \beta_3, \dots, \beta_k$ ：偏回归系数（极其重要，下面单独讲）。
- u_i ：随机扰动项（观测不到的微小因素）。

2.3 灵魂概念：什么是“偏回归系数”？

在一元回归里，斜率表示“ X 变1个单位， Y 变多少”。在多元回归里， β_2 表示：在其他变量 $(X_3 \dots X_k)$ 保持不变（被控制住）的情况下， X_2 变动1个单位，引起 Y_i 的变动量。比喻：如果你研究消费 (Y) 受收入 (X_2) 和财富 (X_3) 影响。 β_2 就是“假设两个人的财富一模一样，收入多1块钱，消费多多少”。这就排除了财富的干扰，让我们看到了收入的“净影响”。

2.4 样本回归函数（我们用样本去猜总体）

总体是我们看不到的，我们只能用样本去估计。所以把真实的 β 换成估计值 $\hat{\beta}$ ，把真实的 u 换成残差 e 。

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki} \quad (3.7)$$

$$Y_i = \hat{Y}_i + e_i \quad (\text{真实值} = \text{预测值} + \text{残差}) \quad (3.8)$$

第三步：让书写变简单——多元线性回归的矩阵形式

写一长串 $X_2, X_3 \dots$ 太累了，还容易看花眼。数学家发明了矩阵，把一长串方程压缩成了极简的几个字母。

3.1 方程组的堆叠（公式3.9）

假设我们有 n 个样本，对于第1个人：

$$\begin{aligned} Y_1 &= \beta_1 + \beta_2 X_{21} + \cdots + \beta_k X_{k1} + u_1 \\ Y_2 &= \beta_1 + \beta_2 X_{22} + \cdots + \beta_k X_{k2} + u_2 \\ &\vdots \\ Y_n &= \beta_1 + \beta_2 X_{2n} + \cdots + \beta_k X_{kn} + u_n \end{aligned}$$

$$\begin{aligned} Y_1 &= \beta_1 + \beta_2 X_{21} + \cdots + \beta_k X_{k1} + u_1 \\ Y_2 &= \beta_1 + \beta_2 X_{22} + \cdots + \beta_k X_{k2} + u_2 \\ &\vdots \\ Y_n &= \beta_1 + \beta_2 X_{2n} + \cdots + \beta_k X_{kn} + u_n \end{aligned} \quad (3.9)$$

3.2 把方程装进盒子里（公式3.10 – 3.11）

我们把等号左边的 Y 全摘出来，竖着排成一列，这就是被解释变量向量 $\mathbf{Y}$ （维度： $n \times 1$ ）：

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

把右边的 X 全摘出来，排成一个表格，这就是**解释变量矩阵 $\mathbf{X}$** （维度： $n \times k$ ）：

$$\mathbf{X} = \begin{bmatrix} 1 & X_{21} & \cdots & X_{k1} \\ 1 & X_{22} & \cdots & X_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{2n} & \cdots & X_{kn} \end{bmatrix}$$

极其关键的细节：第一列全是1！为什么？因为 β_1 是截距项，它没有乘 X ，其实是乘了1。为了矩阵乘法能对齐，必须加一列全1。

把系数排成一列，这就是**参数向量 β** （维度： $k \times 1$ ）：

$$\beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}$$

把扰动项排成一列，这就是**随机扰动项向量 $\mathbf{U}$** （维度： $n \times 1$ ）：

$$\mathbf{U} = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}$$

现在，那一长串方程变成了极其优雅的矩阵等式（3.11）：

$$\mathbf{Y} = \mathbf{X}\beta + \mathbf{U} \quad (3.11)$$

同理，样本的矩阵形式（3.13, 3.14）就是：

$$\mathbf{Y} = \mathbf{X}\hat{\beta} + \mathbf{e} \quad (3.13, 3.14)$$

（其中 $\hat{\beta}$ 是估计值向量， $\mathbf{e}$ 是残差向量）

第四步：游戏的规则——多元线性回归模型的古典假定

要想用最小二乘法（OLS）算出来的 $\hat{\beta}$ 是靠谱的（无偏、有效），总体模型必须满足5个前提假定。这些假定是一切推导的基石。

假定1：零均值假定——扰动项是个纯粹的白噪声

- 标量表达： $E(u_i) = 0$ （对任何第 i 个观测，扰动项的期望为0）
- 矩阵表达： $E(\mathbf{U}) = \mathbf{0}$ （一个全是0的 $n \times 1$ 列向量）

- 大白话：扰动项有时正有时负，但平均来看它不偏不倚，不带有系统性的偏差。

假定2：同方差和无自相关假定——扰动项不乱蹦

- 同方差标量： $\text{Var}(u_i) = E(u_i^2) = \sigma^2$ （每个扰动项的波动幅度一样大）
- 无自相关标量： $\text{Cov}(u_i, u_j) = E(u_i u_j) = 0 \ (i \neq j)$ （不同观测的扰动项互不干扰，张三的误差不影响李四）
- 矩阵表达：

$$\text{Var} - \text{Cov}(\mathbf{U}) = E(\mathbf{U}\mathbf{U}') = \sigma^2 \mathbf{I}_n \quad (3.16, 3.17)$$

– 拆解这个看起来吓人的矩阵： $\mathbf{U}\mathbf{U}'$ 是一个 $n \times n$ 的方阵。对角线上的元素是 u_i^2 ，取期望变成 σ^2 （同方差）；非对角线上的元素是 $u_i u_j$ ，取期望变成0（无自相关）。所以整个矩阵，对角线全是 σ^2 ，其他全是0，正好乘以一个单位矩阵 $\mathbf{I}_n$ ！

假定3：随机扰动项与解释变量不相关——X里没有混入u

- 表达： $\text{Cov}(X_{ji}, u_i) = 0$
- 大白话：解释变量X是外生的，它不是由u决定的。比如你研究收入对消费的影响，收入这个变量本身不是由模型里的随机误差决定的。

假定4：无多重共线性假定——解释变量之间不能互相抄

- 表达：矩阵 $\mathbf{X}$ 的列满秩， $\text{Rank}(\mathbf{X}) = k$ （公式3.20）；方阵 $\mathbf{X}'\mathbf{X}$ 满秩， $\text{Rank}(\mathbf{X}'\mathbf{X}) = k$ 且可逆（公式3.21）。
- 大白话：你放进模型里的 k 个X变量，必须各自提供独立的信息，不能有一个X是可以由其他X加减乘除算出来的。
- 为什么必须可逆？因为后续推导参数估计量时，公式里一定会出现 $(\mathbf{X}'\mathbf{X})^{-1}$ 。如果矩阵不可逆（行列式为0），除以0就天塌了，算不出参数！

假定5：正态性假定——为了做假设检验

- 表达： $u_i \sim N(0, \sigma^2)$
- 矩阵表达： $\mathbf{U} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$
- 大白话：扰动项不仅均值为0、方差为 σ^2 ，而且它的分布是完美的钟形曲线（正态分布）。这个假定在后续做 t 检验、F 检验时是必须的。

第五步：总结

整篇内容的逻辑链条如下：

1. **为什么要多元：**现实影响因素多，一元不够用；非线性可以通过取对数变成多元线性。
2. **标量到矩阵：**多元模型写一长串太繁琐，用矩阵 $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{U}$ 压缩表达，且矩阵运算在计算机（如EViews）中运行极快。
3. **核心概念：**偏回归系数意味着“控制其他变量不变时的净影响”。
4. **古典假定：**为了让OLS估计量具备“优良性质（BLUE）”，必须满足零均值、同方差无自相关、外生性、无多重共线性和正态性这五大游戏规则。后续所有的研究方法，都建立在这5条规则成立的基础之上。