

多元线性回归模型的估计——极详细推导与讲解

1 引言

本文以初学者能跟上的细致程度，讲解多元线性回归模型参数的最小二乘估计、估计量的统计性质（线性性、无偏性、最小方差性）、估计量的分布性质，以及随机扰动项方差的估计。每一步代数变形、每一个矩阵运算、每一个概念转换都给出解释，绝不跳步。

2 第一步：多元线性回归模型参数的最小二乘估计

2.1 1.1 我们要解决什么问题？

回忆一下简单线性回归：只有一个解释变量 X ，模型是 $Y_i = \beta_1 + \beta_2 X_i + u_i$ ，我们用一条直线去拟合数据。

现在情况升级了：我们有多个解释变量 $X_2, X_3, \dots, X_k$ ，模型变成了：

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \dots + \beta_k X_{ki} + u_i$$

- Y_i ：被解释变量（因变量）的第 i 个观测值。
- $X_{2i}, X_{3i}, \dots, X_{ki}$ ： $k - 1$ 个解释变量的第 i 个观测值。
- β_1 ：截距项。
- $\beta_2, \beta_3, \dots, \beta_k$ ：各个解释变量的偏回归系数。
- u_i ：随机扰动项。
- $i = 1, 2, \dots, n$ ：共 n 个样本观测值。

我们的目标：用样本数据把 $\beta_1, \beta_2, \dots, \beta_k$ 这些未知参数估计出来。

核心思路和简单回归完全一样：找到一组参数估计值 $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k$ ，使得样本回归函数“尽可能接近”真实数据。而“尽可能接近”的数学标准就是——使残差平方和最小。

2.2 1.2 残差与残差平方和

设样本回归函数为：

$$\hat{Y}_i = \hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \hat{\beta}_3 X_{3i} + \cdots + \hat{\beta}_k X_{ki}$$

那么第 i 个观测的残差（也叫剩余）就是真实值与估计值之间的差距：

$$e_i = Y_i - \hat{Y}_i = Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \hat{\beta}_3 X_{3i} + \cdots + \hat{\beta}_k X_{ki}) \quad (3.22)$$

暂停理解一下：残差 e_i 就是回归线没“抓住”的那部分。如果回归线完美， $e_i = 0$ 对所有 i 成立。

我们要让所有残差的平方加起来尽可能小：

$$\sum e_i^2 = \sum [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \hat{\beta}_3 X_{3i} + \cdots + \hat{\beta}_k X_{ki})]^2$$

为什么用平方？和简单回归一样的道理——残差有正有负，直接加会抵消，平方之后全部变正，远的点惩罚更重。

2.3 1.3 对每个参数求偏导——建立正规方程组

这是一个关于 $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k$ 的多元函数求最小值问题。微积分告诉我们：函数在某点取得极值的必要条件是，对每个变量的偏导数等于零。

所以，对每个 $\hat{\beta}_j$ ($j = 1, 2, \dots, k$) 求偏导：

$$\frac{\partial(\sum e_i^2)}{\partial \hat{\beta}_j} = 0 \quad (j = 1, 2, \dots, k)$$

下面我们一个一个来算。

对 $\hat{\beta}_1$ 求偏导：

$$\frac{\partial}{\partial \hat{\beta}_1} \sum [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})]^2$$

方括号内对 $\hat{\beta}_1$ 求导，得到 -1 （因为 $\hat{\beta}_1$ 的系数是 -1 ），再用链式法则乘以外面的 2 倍方括号本身：

$$= \sum 2 \cdot [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})] \cdot (-1) = 0$$

化简，把 -2 约掉：

$$- \sum [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})] = 0$$

即：

$$\sum [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})] = 0$$

注意方括号里就是 e_i ，所以这等价于 $\sum e_i = 0$ 。

对 $\hat{\beta}_2$ 求偏导：

$$\frac{\partial}{\partial \hat{\beta}_2} \sum [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})]^2$$

方括号内对 $\hat{\beta}_2$ 求导，得到 $-X_{2i}$ ，再用链式法则：

$$= \sum 2 \cdot [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})] \cdot (-X_{2i}) = 0$$

化简：

$$- \sum X_{2i} [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})] = 0$$

同样，方括号里是 e_i ，所以等价于 $\sum X_{2i} e_i = 0$ 。

对 $\hat{\beta}_k$ 求偏导（一般情形）：

同理可得：

$$- \sum X_{ki} [Y_i - (\hat{\beta}_1 + \hat{\beta}_2 X_{2i} + \cdots + \hat{\beta}_k X_{ki})] = 0$$

等价于 $\sum X_{ki} e_i = 0$ 。

把所有 k 个方程写在一起：

$$\begin{cases} \sum e_i = 0 \\ \sum X_{2i} e_i = 0 \\ \vdots \\ \sum X_{ki} e_i = 0 \end{cases}$$

暂停理解一下：这 k 个方程叫做**正规方程组**（normal equations）。它们的含义是——残差与每个解释变量（包括常数项1）的样本内积为零。直观上说，回归线已经把每个解释变量能解释的信息全部“榨取”干净了，剩下的残差跟任何解释变量都不相关。

2.4 1.4 正规方程组的矩阵表示

用矩阵来写，可以非常简洁。先把上面的 k 个方程写成向量形式：

$$\begin{bmatrix} \sum e_i \\ \sum X_{2i}e_i \\ \vdots \\ \sum X_{ki}e_i \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

现在看左边这个向量——它的每一行恰好是矩阵 $\mathbf{X}'$ 的一行与残差向量 $\mathbf{e}$ 的乘积。
为什么？

回顾数据矩阵 $\mathbf{X}$ 的定义：

$$\mathbf{X} = \begin{bmatrix} 1 & X_{21} & \cdots & X_{k1} \\ 1 & X_{22} & \cdots & X_{k2} \\ \vdots & \vdots & & \vdots \\ 1 & X_{2n} & \cdots & X_{kn} \end{bmatrix}$$

$\mathbf{X}$ 是 $n \times k$ 矩阵，第一列全为1（对应截距项），其余列是各解释变量的观测值。

$\mathbf{X}$ 的转置 $\mathbf{X}'$ 是 $k \times n$ 矩阵：

$$\mathbf{X}' = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ X_{21} & X_{22} & \cdots & X_{2n} \\ \vdots & \vdots & & \vdots \\ X_{k1} & X_{k2} & \cdots & X_{kn} \end{bmatrix}$$

残差向量 $\mathbf{e} = \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix}$ 是 $n \times 1$ 列向量。

那么 $\mathbf{X}'\mathbf{e}$ 就是 $k \times 1$ 向量：

$$\mathbf{X}'\mathbf{e} = \begin{bmatrix} 1 \cdot e_1 + 1 \cdot e_2 + \cdots + 1 \cdot e_n \\ X_{21}e_1 + X_{22}e_2 + \cdots + X_{2n}e_n \\ \vdots \\ X_{k1}e_1 + X_{k2}e_2 + \cdots + X_{kn}e_n \end{bmatrix} = \begin{bmatrix} \sum e_i \\ \sum X_{2i}e_i \\ \vdots \\ \sum X_{ki}e_i \end{bmatrix}$$

正好就是左边的向量！所以正规方程组可以极其简洁地写成：

$$\mathbf{X}'\mathbf{e} = \mathbf{0} \quad (3.23)$$

2.5 1.5 从正规方程组解出参数估计量

现在我们有 $\mathbf{X}'\mathbf{e} = \mathbf{0}$ ，但里面含有残差 $\mathbf{e}$ ，而 $\mathbf{e}$ 又依赖于 $\hat{\boldsymbol{\beta}}$ 。我们需要把 $\mathbf{e}$ 用 $\hat{\boldsymbol{\beta}}$ 替换掉。

回忆样本回归函数的矩阵形式。总体回归模型的矩阵形式是：

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{U}$$

样本回归函数是：

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

残差向量为：

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$$

对样本回归函数两边同乘 $\mathbf{X}'$ ：

$$\mathbf{X}'\mathbf{Y} = \mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{X}'\mathbf{e} \quad (3.24)$$

暂停理解一下：这一步就是把 $\mathbf{Y} = \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{e}$ 两边左乘 $\mathbf{X}'$ ，然后用分配律展开。右边出现了 $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}}$ 和 $\mathbf{X}'\mathbf{e}$ 两项。

由式 (3.23)， $\mathbf{X}'\mathbf{e} = \mathbf{0}$ ，所以第二项消失，得到：

$$\mathbf{X}'\mathbf{Y} = \mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} \quad (3.25)$$

这就是矩阵形式的正规方程组。

现在要解这个方程，把 $\hat{\boldsymbol{\beta}}$ 解出来。 $\mathbf{X}'\mathbf{X}$ 是一个 $k \times k$ 的方阵。由古典假定中的无多重共线性假定， $\mathbf{X}'\mathbf{X}$ 是可逆的，即 $(\mathbf{X}'\mathbf{X})^{-1}$ 存在。

（为什么无多重共线性就能保证可逆？无多重共线性意味着 $\mathbf{X}$ 的列向量线性无关，而 $\mathbf{X}'\mathbf{X}$ 可逆的充要条件恰好就是 $\mathbf{X}$ 列满秩，即列向量线性无关。）

在式 (3.25) 两边左乘 $(\mathbf{X}'\mathbf{X})^{-1}$ ：

$$(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}}$$

右边 $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{I}_k$ （单位矩阵），所以：

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \quad (3.26)$$

这就是多元线性回归模型参数向量最小二乘估计的矩阵表达式。这是一个极其重要、必须牢记的公式。

暂停理解一下：这个公式告诉我们——给定数据 $\mathbf{X}$ 和 $\mathbf{Y}$ ，只需要做矩阵运算 $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ ，就能一步得到所有参数的OLS估计值。在实际操作中，这就是计算机软件（如EViews、Stata、R）在做的事情。

2.6 1.6 两个解释变量时的代数表达式

对于只有两个解释变量的模型 $Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$ ， $\hat{\beta}_2$ 有一个具体的代数表达式（用离差形式表示）：

$$\hat{\beta}_2 = \frac{\sum y_i x_{2i} \sum x_{3i}^2 - \sum y_i x_{3i} \sum x_{2i} x_{3i}}{\sum x_{2i}^2 \sum x_{3i}^2 - (\sum x_{2i} x_{3i})^2} \quad (3.27)$$

其中 $x_{ti} = X_{ti} - \bar{X}_t$ ， $y_i = Y_i - \bar{Y}$ （小写字母表示离差形式）。

暂停理解一下：这个公式看起来复杂，但逻辑是清晰的——当只有一个解释变量时， $\hat{\beta}_2 = \frac{\sum y_i x_{2i}}{\sum x_{2i}^2}$ ；现在多了一个解释变量 X_3 ，它可能会“混淆” X_2 对 Y 的影响，所以分子和分母都要做“净化”调整——把 X_2 和 X_3 之间的交叉影响考虑进去。分母中的 $\sum x_{2i}^2 \sum x_{3i}^2 - (\sum x_{2i} x_{3i})^2$ 本质上就是在衡量 X_2 和 X_3 之间是否有重叠信息。

2.7 1.7 例3.1的计算

书上用2000~2020年中国货币供应量（M2） Y_t 、GDP X_{2t} 、CPI X_{3t} 的数据来演示。

把数据排成矩阵：

$$\mathbf{Y} = \begin{bmatrix} 134610.3 \\ 158301.9 \\ \vdots \\ 2186795.9 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 100280.1 & 434.0 \\ 1 & 110863.1 & 437.0 \\ \vdots & \vdots & \vdots \\ 1 & 1015986.2 & 686.5 \end{bmatrix}$$

代入公式 $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ ，计算得到：

$$\hat{\beta} = \begin{bmatrix} 954083.0 \\ 2.878165 \\ -2601.117 \end{bmatrix}$$

所以样本回归模型为：

$$\hat{Y}_i = 954083.0 + 2.878165X_{2i} - 2601.117X_{3i}$$

直观理解：

- GDP每增加1亿元，M2平均增加约2.88亿元（CPI不变时）。

- CPI每增加1个点，M2平均减少约2601亿元（GDP不变时）——这看起来反直觉，可能是多重共线性等原因导致，后续章节会讨论。

3 第二步：参数最小二乘估计的性质

从式 (3.26) $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 可以看出，参数估计量是样本观测值 $\mathbf{Y}$ 的函数。由于每次抽样的 $\mathbf{Y}$ 不同， $\hat{\beta}$ 也不同——它是随抽样而变化的随机变量。

在古典假定成立的前提下，OLS估计量有三个优良性质：线性性、无偏性、最小方差性。合起来叫做最佳线性无偏估计量（BLUE）。下面逐一证明。

3.1 2.1 性质一：线性性

目标：证明 $\hat{\beta}$ 是 $\mathbf{Y}$ 的线性函数。

由式 (3.26)：

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

这里 $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ 是一个 $k \times n$ 的矩阵，它只依赖于解释变量矩阵 $\mathbf{X}$ 。由古典假定， $\mathbf{X}$ 是固定不变的（非随机的）。所以 $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ 是一个常数矩阵。

设 $\mathbf{A} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ ，则 $\hat{\beta} = \mathbf{A}\mathbf{Y}$ 。

这就意味着 $\hat{\beta}$ 的每一个分量 $\hat{\beta}_j$ 都是 $\mathbf{Y}$ 的各分量 $Y_1, Y_2, \dots, Y_n$ 的线性组合（加权和），权数仅由 $\mathbf{X}$ 决定。

线性性得证。

3.2 2.2 性质二：无偏性

目标：证明 $E(\hat{\beta}) = \beta$ 。

首先，我们需要一个关键的表达式。把总体模型 $\mathbf{Y} = \mathbf{X}\beta + \mathbf{U}$ 代入 $\hat{\beta}$ 的公式：

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{U})$$

展开括号：

$$= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{U}$$

第一项 $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{I}_k$ ，所以：

$$\hat{\beta} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{U} \quad (3.29)$$

暂停理解一下：这个结果非常重要，它是后面推导无偏性和方差的基础。它告诉我们——估计量 $\hat{\beta}$ 等于真实参数 β 加上一个由随机扰动 U 引起的“偏移” $(X'X)^{-1}X'U$ 。如果 $U = 0$ （没有随机扰动）， $\hat{\beta}$ 就精确等于 β 。

现在对两边取期望：

$$E(\hat{\beta}) = E[\beta + (X'X)^{-1}X'U]$$

因为 β 是常数向量， $(X'X)^{-1}X'$ 是常数矩阵（ X 固定），可以把期望算子移进去：

$$= \beta + (X'X)^{-1}X'E(U)$$

由古典假定中的**零均值假定**： $E(U) = 0$ ，所以：

$$E(\hat{\beta}) = \beta + (X'X)^{-1}X' \cdot 0 = \beta + 0 = \beta \quad (3.30)$$

无偏性得证。

直观理解：虽然每一次抽样得到的 $\hat{\beta}$ 不一定等于 β ，但如果我们重复抽样很多很多次，所有这些 $\hat{\beta}$ 的平均值恰好等于真实值 β 。系统上没有偏高也没有偏低的倾向。

3.3 2.3 性质三：最小方差性（有效性）

目标：证明在所有线性无偏估计量中，OLS估计量 $\hat{\beta}$ 的方差最小。

这个证明较为繁琐（需要构造任意的线性无偏估计量，然后证明其方差与OLS方差之差是半正定矩阵），书上将其放在附录3.1中。

但结论必须牢记：在古典假定全部满足的条件下，OLS估计量是**最佳线性无偏估计量（BLUE）**——“最佳”就是指方差最小，“线性无偏”就是前两个性质。

这就是著名的高斯-马尔可夫定理在多元情形下的体现。

综合三个性质：

性质	含义	通俗理解
线性性	$\hat{\beta}$ 是 Y 的线性组合	估计量形式简单
无偏性	$E(\hat{\beta}) = \beta$	平均而言不偏
最小方差性	在线性无偏估计中方差最小	估计最稳定、最精确

三者合起来 = **BLUE**（Best Linear Unbiased Estimator）。

4 第三步：OLS估计的分布性质

4.1 3.1 为什么需要知道分布？

前面我们知道了 $\hat{\beta}$ 的期望和方差，但要进行区间估计（比如算置信区间）和假设检验（比如检验某个系数是否显著），仅有期望和方差是不够的，还需要知道 $\hat{\beta}$ 服从什么分布。

4.2 3.2 正态性的推导

由古典假定中的正态性假定， u_i 服从正态分布： $u_i \sim N(0, \sigma^2)$ 。
因为 $\mathbf{U}$ 的每个分量 u_i 都是正态的，所以：

$$\mathbf{Y} = \mathbf{X}\beta + \mathbf{U}$$

$\mathbf{Y}$ 是正态随机向量 $\mathbf{U}$ 的线性变换（ $\mathbf{X}\beta$ 是常数，加上 $\mathbf{U}$ ），所以 $\mathbf{Y}$ 也服从正态分布。

由线性性， $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ ，即 $\hat{\beta}$ 是 $\mathbf{Y}$ 的线性变换。正态分布的线性变换仍然是正态分布。所以 $\hat{\beta}$ 服从正态分布。

逻辑链： u_i 正态 $\Rightarrow \mathbf{U}$ 正态 $\Rightarrow \mathbf{Y}$ 正态 $\Rightarrow \hat{\beta}$ 正态。

4.3 3.3 方差-协方差矩阵的推导（极其详细，无跳步）

我们已经知道 $\hat{\beta}$ 服从正态分布，也知道了它的均值 $E(\hat{\beta}) = \beta$ 。现在要推导它的方差-协方差矩阵。

定义回顾：随机向量 $\mathbf{Z}$ 的方差-协方差矩阵为：

$$\text{Var-Cov}(\mathbf{Z}) = E\{[\mathbf{Z} - E(\mathbf{Z})][\mathbf{Z} - E(\mathbf{Z})]'\}$$

对角线元素是各分量的方差，非对角线元素是两两之间的协方差。

推导开始：

由无偏性， $E(\hat{\beta}) = \beta$ ，所以：

$$\text{Var-Cov}(\hat{\beta}) = E\{[\hat{\beta} - \beta][\hat{\beta} - \beta]'\}$$

由式 (3.29)： $\hat{\beta} - \beta = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{U}$ ，代入：

$$= E\{[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{U}][(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{U}]'\}$$

现在处理转置部分。回忆矩阵转置的性质 $(\mathbf{AB})' = \mathbf{B}'\mathbf{A}'$ ：

$$[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{U}]' = \mathbf{U}'\mathbf{X}[(\mathbf{X}'\mathbf{X})^{-1}]' = \mathbf{U}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

（这里用到了 $(\mathbf{X}'\mathbf{X})^{-1}$ 是对称矩阵，所以它的转置等于自身。为什么？因为 $(\mathbf{X}'\mathbf{X})' = \mathbf{X}'\mathbf{X}$ ，即 $\mathbf{X}'\mathbf{X}$ 本身对称，其逆矩阵也对称。）

代入回去：

$$= E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{U}\mathbf{U}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}]$$

现在把常数矩阵移到期望外面。 $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ 是常数矩阵（在 $\mathbf{X}$ 固定条件下）， $(\mathbf{X}'\mathbf{X})^{-1}$ 也是常数矩阵。唯一随机的是 $\mathbf{U}\mathbf{U}'$ 。所以：

$$= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'E(\mathbf{U}\mathbf{U}')\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

关键跳跃点解释： $E(\mathbf{U}\mathbf{U}')$ 是什么？由古典假定中的同方差和无自相关假定：

$$E(\mathbf{U}\mathbf{U}') = E \begin{bmatrix} u_1^2 & u_1u_2 & \cdots & u_1u_n \\ u_2u_1 & u_2^2 & \cdots & u_2u_n \\ \vdots & \vdots & \ddots & \vdots \\ u_nu_1 & u_nu_2 & \cdots & u_n^2 \end{bmatrix} = \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{bmatrix} = \sigma^2 \mathbf{I}_n$$

- 对角线上： $E(u_i^2) = \text{Var}(u_i) = \sigma^2$ （同方差假定）
- 非对角线上： $E(u_iu_j) = \text{Cov}(u_i, u_j) = 0$ （ $i \neq j$ ，无自相关假定）

所以 $E(\mathbf{U}\mathbf{U}') = \sigma^2 \mathbf{I}_n$ 。

代入：

$$= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\sigma^2\mathbf{I}_n\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

$\sigma^2\mathbf{I}_n$ 是标量乘单位矩阵，可以提到最前面； $\mathbf{I}_n\mathbf{X} = \mathbf{X}$ （单位矩阵乘任何矩阵等于该矩阵自身）：

$$= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

$(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{I}_k$ ，所以：

$$\text{Var-Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2\mathbf{I}_k(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (3.31)$$

方差-协方差矩阵推导完毕！

$$\text{Var-Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

4.4 3.4 单个参数的方差与标准误差

方差-协方差矩阵的对角线第 j 个元素就是 $\hat{\beta}_j$ 的方差。设 $(\mathbf{X}'\mathbf{X})^{-1}$ 的第 j 行第 j 列元素为 c_{jj} ，则：

$$\text{Var}(\hat{\beta}_j) = \sigma^2 c_{jj} \quad (3.32)$$

$$\text{SE}(\hat{\beta}_j) = \sigma \sqrt{c_{jj}} \quad (3.33)$$

其中 c_{jj} 是 $(\mathbf{X}'\mathbf{X})^{-1}$ 中第 j 行第 j 列的元素。

4.5 3.5 分布结论

综合以上，在古典假定下， $\hat{\beta}_j$ 服从正态分布：

$$\hat{\beta}_j \sim N[\beta_j, \sigma^2 c_{jj}] \quad (3.34)$$

- 均值是 β_j （由无偏性保证）
- 方差是 $\sigma^2 c_{jj}$ （由方差-协方差矩阵得出）

暂停理解一下：知道 $\hat{\beta}_j$ 服从正态分布后，我们就可以对它做标准化变换 $\frac{\hat{\beta}_j - \beta_j}{\sigma \sqrt{c_{jj}}} \sim N(0, 1)$ ，然后用标准正态分布表来进行假设检验和区间估计。但实际上 σ 未知，需要用估计值替代，那就涉及 t 分布——这是后续内容。

5 第四步：随机扰动项方差的估计

5.1 4.1 为什么需要估计 σ^2 ？

参数估计量的方差 $\text{Var}(\hat{\beta}_j) = \sigma^2 c_{jj}$ 中， c_{jj} 是可以计算的（给定数据 $\mathbf{X}$ 后， $(\mathbf{X}'\mathbf{X})^{-1}$ 就确定了），但 σ^2 是总体随机扰动项的方差，是未知的。

不知道 σ^2 ，就没法算出 $\text{Var}(\hat{\beta}_j)$ 的具体数值，也就没法做假设检验和区间估计。所以必须想办法用样本数据来估计 σ^2 。

5.2 4.2 残差向量与残差平方和

在得到参数估计值 $\hat{\beta}$ 之后，可以计算残差向量：

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\beta}$$

残差平方和为：

$$\sum e_i^2 = \mathbf{e}'\mathbf{e}$$

5.3 4.3 σ^2 的无偏估计（极其详细推导）

可以证明（证明见书上附录3.2）：

$$E\left(\sum e_i^2\right) = E(\mathbf{e}'\mathbf{e}) = (n-k)\sigma^2$$

暂停理解一下：为什么是 $(n-k)$ 而不是 n ？因为我们在估计 k 个参数 $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_k$ 的过程中，消耗了 k 个自由度，所以残差平方和的期望不再是 $n\sigma^2$ ，而是 $(n-k)\sigma^2$ 。

由上式可得：

$$E\left(\frac{\sum e_i^2}{n-k}\right) = \sigma^2 \quad (3.35)$$

这意味着 $\frac{\sum e_i^2}{n-k}$ 的期望恰好等于 σ^2 ——它是一个**无偏估计量**。

定义：

$$\hat{\sigma}^2 = \frac{\sum e_i^2}{n-k} \quad (3.36)$$

则 $\hat{\sigma}^2$ 就是 σ^2 的无偏估计。 $\hat{\sigma}^2$ 称为**估计的方差**， $\hat{\sigma}$ 称为**估计的标准误差**。

5.4 4.4 参数方差的估计式

既然 σ^2 的无偏估计是 $\hat{\sigma}^2$ ，我们用 $\hat{\sigma}^2$ 替代 σ^2 ，得到参数估计量方差的估计式：

$$\widehat{\text{Var}}(\hat{\beta}_j) = \hat{\sigma}^2 c_{jj} = \left(\frac{\sum e_i^2}{n-k}\right) c_{jj} \quad (3.37)$$

暂停理解一下：注意这里多了一个“帽子” $\widehat{\text{Var}}$ ，表示这是方差的**估计值**，而不是方差本身。 $\text{Var}(\hat{\beta}_j) = \sigma^2 c_{jj}$ 是理论公式（含有未知的 σ^2 ），而 $\widehat{\text{Var}}(\hat{\beta}_j) = \hat{\sigma}^2 c_{jj}$ 是可以实际计算的数值。

5.5 4.5 例3.1的数值计算

回到货币供应量的例子。 $n = 21$ （2000~2020年共21个观测值）， $k = 3$ （截距 + GDP系数 + CPI系数）。

步骤1：计算残差平方和

通过回归计算得到 $\sum e_i^2 = 36,623,503,360$ 。

步骤2：计算 $\hat{\sigma}^2$

$$\hat{\sigma}^2 = \frac{\sum e_i^2}{n-k} = \frac{36,623,503,360}{21-3} = \frac{36,623,503,360}{18} = 2,034,639,104.00$$

步骤3：计算各参数估计量的方差

需要知道 $(\mathbf{X}'\mathbf{X})^{-1}$ 对角线上的元素 c_{11}, c_{22}, c_{33} 。通过计算得到 $c_{22} = 0.0000000002602$ （极小，因为GDP数值很大，导致 $\mathbf{X}'\mathbf{X}$ 的元素很大，逆矩阵元素就很小）。

$$\widehat{\text{Var}}(\hat{\beta}_2) = \hat{\sigma}^2 \cdot c_{22} = 2,034,639,104.00 \times 0.00000000002602 = 0.0529$$

同理：

$$\widehat{\text{Var}}(\hat{\beta}_1) = 118,064,029,467.478$$

$$\widehat{\text{Var}}(\hat{\beta}_3) = 682,002.861$$

直观理解： $\hat{\beta}_2$ 的方差只有0.0529，而 $\hat{\beta}_2 = 2.878165$ ，标准误约为 $\sqrt{0.0529} \approx 0.23$ ，相对于系数值2.88来说很小，说明GDP对M2的影响估计得比较精确。而 $\hat{\beta}_1$ 的方差极大（超过千亿元级别），这是因为截距项的估计精度本来就受数据尺度影响很大。

6 总结

整篇文章的逻辑链条如下：

1. **估计方法：**用最小二乘法使残差平方和最小，对 k 个参数求偏导得到正规方程组 $\mathbf{X}'\mathbf{e} = \mathbf{0}$ ，进而解出 $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 。
2. **估计量的性质（BLUE）：**
 - **线性性：** $\hat{\beta}$ 是 $\mathbf{Y}$ 的线性函数，系数只与 $\mathbf{X}$ 有关。
 - **无偏性：** $E(\hat{\beta}) = \beta$ ，利用零均值假定 $E(\mathbf{U}) = \mathbf{0}$ 得到。
 - **最小方差性：**在所有线性无偏估计量中方差最小（高斯-马尔可夫定理）。
3. **分布性质：**在正态性假定下， $\hat{\beta}_j \sim N[\beta_j, \sigma^2 c_{jj}]$ ，方差-协方差矩阵为 $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ 。
4. **σ^2 的估计：** $\hat{\sigma}^2 = \frac{\sum e_i^2}{n-k}$ 是 σ^2 的无偏估计，自由度 $n-k$ 反映了估计 k 个参数消耗的自由度。用 $\hat{\sigma}^2$ 替代 σ^2 ，就可以算出参数估计量方差的数值。