

什么是多重共线性——极详细讲解

引言

本文以初学者能跟上的细致程度，逐步讲解计量经济学中“多重共线性”的概念。我们会从最基本的问题出发：什么叫“解释变量之间有线形关系”？什么叫“完全的”和“不完全的”？用矩阵怎么看？实际经济问题中为什么会发生？每一步定义、每一个公式、每一个符号都不跳过。

第一步：我们要解决什么问题？（引入概念）

回忆一下第三章：我们讨论多元线性回归模型的估计时，有一个很重要的假定——**无多重共线性**。也就是说，我们假定了“各解释变量之间不存在线性关系”。

但这句话到底是什么意思？什么叫“线性关系”？什么叫“不存在”？如果存在，又分几种情况？

这些就是本节要回答的问题。

- **多重共线性 (multi-collinearity)**：简单说，就是解释变量之间存在线性关系（或近似线性关系）的现象。

但要注意，计量经济学中所说的多重共线性，范围比纯数学的“线性相关”更广——它不仅包括**精确**的线性关系，还包括**近似**的线性关系。这一点非常关键，后面我们会用数学公式严格区分。

第二步：把截距项也看成解释变量——统一书写

我们先看一个带截距项的多元线性回归模型：

$$Y_i = \beta_1 + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i \quad (1)$$

这里有 $k - 1$ 个解释变量 $X_2, X_3, \dots, X_k$ ，加上截距项 β_1 ，共有 k 个参数。

现在做一个看似小、实则重要的改写：**把截距项 β_1 也看作某个解释变量前面的系数**。

怎么做到呢？我们定义一个恒等于 1 的“解释变量” X_{1i} ，即对所有的 $i = 1, 2, \dots, n$ ，都有 $X_{1i} = 1$ 。

于是模型 (??) 可以等价地写成：

$$Y_i = \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i \quad (2)$$

其中 $X_{1i} = 1$ 。

暂停理解一下：为什么要这么写？因为这样做的目的是**统一格式**。现在每一个 β_j （包括截距项 β_1 ）都是某个 X_j 的系数，不再对截距项做特殊对待。这让我们后面用数学语言定义多重共线性时，公式更简洁、更统一。

第三步：完全多重共线性的数学定义

3.1 定义

如果存在不全为 0 的数 $\lambda_1, \lambda_2, \dots, \lambda_k$ ，使得对每一个观测 $i = 1, 2, \dots, n$ ，都有：

$$\lambda_1 X_{1i} + \lambda_2 X_{2i} + \cdots + \lambda_k X_{ki} = 0 \quad (3)$$

则称解释变量 $X_1, X_2, \dots, X_k$ 之间存在**完全的多重共线性**。

3.2 逐字逐句解释这个定义

我们来拆解定义中的每一个关键词：

“不全为 0”：这意味着 $\lambda_1, \lambda_2, \dots, \lambda_k$ 这 k 个数里面，至少有一个不是 0。注意，不是要求全部不为 0，而是不能全部为 0。

- 如果所有 λ 全是 0，那 $\lambda_1 X_{1i} + \cdots + \lambda_k X_{ki} = 0$ 当然成立，但这毫无意义——0 加 0 永远等于 0，不能说明任何关系。
- 所以“不全为 0”保证了这个等式确实揭示了变量之间的某种联系。

“对每一个观测 $i = 1, 2, \dots, n$ 都成立”：这意味着等式 (??) 不是一个偶然现象，而是对所有 n 个样本点都成立。换句话说，变量之间的线性关系不是只碰巧在某个点上出现，而是系统性地存在于整个样本中。

一个直觉理解：举个例子。假设 $k = 3$ ，即有三个解释变量 X_1, X_2, X_3 （其中 $X_1 \equiv 1$ ）。如果 $\lambda_1 = 2, \lambda_2 = 3, \lambda_3 = -1$ ，而且对每个 i 都有 $2X_{1i} + 3X_{2i} - X_{3i} = 0$ ，那就可以写成 $X_{3i} = 2 + 3X_{2i}$ 。这说明 X_3 完全可以由 X_2 （和常数）决定—— X_3 没有带来任何独立的信息。

第四步：用矩阵语言表述完全多重共线性

4.1 数据矩阵

我们把所有解释变量的观测值排成一个 $n \times k$ 的矩阵 $\mathbf{X}$ ：

$$\mathbf{X} = \begin{pmatrix} X_{11} & X_{21} & X_{31} & \cdots & X_{k1} \\ X_{12} & X_{22} & X_{32} & \cdots & X_{k2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ X_{1n} & X_{2n} & X_{3n} & \cdots & X_{kn} \end{pmatrix} \quad (4)$$

逐行解读：

- 第 1 列是 X_1 的 n 个观测值。因为 $X_{1i} = 1$ ，所以第 1 列全是 1。
- 第 2 列是 X_2 的 n 个观测值。
- 以此类推，第 k 列是 X_k 的 n 个观测值。
- 每一行对应一个样本点（第 i 个家庭、第 i 年等）。

4.2 秩 (Rank) 与多重共线性的关系

矩阵的秩 $\text{Rank}(\mathbf{X})$ 的含义是：矩阵中线性无关的列向量的最大个数。

- $\mathbf{X}$ 有 k 列。如果这 k 列全部线性无关，那么 $\text{Rank}(\mathbf{X}) = k$ （满秩）。
- 如果这 k 列中至少有一列可以由其余列线性表示，那就存在完全多重共线性，此时 $\text{Rank}(\mathbf{X}) < k$ 。

暂停理解一下：什么叫“一列可以由其余列线性表示”？就是说，某一列等于其他几列的加权求和。比如，如果第 3 列 = $2 \times$ 第 1 列 + $5 \times$ 第 2 列，那么第 3 列完全没有独立信息——它就是第 1 列和第 2 列的组合。这就是完全多重共线性的矩阵视角。

4.3 结论

当 $\text{Rank}(\mathbf{X}) < k$ 时，存在完全的多重共线性。

当 $\text{Rank}(\mathbf{X}) = k$ 时，不存在完全的多重共线性（矩阵满秩）。

第五步：不完全多重共线性——实际中更常见的情形

5.1 为什么完全多重共线性罕见？

完全多重共线性要求对每一个观测 i ，等式 (??) 都精确成立——不多不少，恰好等于 0。

但现实经济数据中，变量之间的关系几乎不可能完美到每个数据点都严丝合缝。比如，收入和消费高度相关，但不可能每一年都精确满足 $9 = 2 + 0.7 \times 6e$ ，总会有些扰动。

所以，更常见的是不完全的多重共线性。

5.2 定义

如果存在不全为 0 的数 $\lambda_1, \lambda_2, \dots, \lambda_k$ ，使得：

$$\lambda_1 X_{1i} + \lambda_2 X_{2i} + \lambda_3 X_{3i} + \dots + \lambda_k X_{ki} + v_i = 0 \quad (i = 1, 2, \dots, n) \quad (5)$$

其中 v_i 是随机变量（随机扰动项），则称解释变量 $X_1, X_2, \dots, X_k$ 之间存在**不完全的多重共线性**。

5.3 对比完全 vs 不完全

对比项	完全多重共线性	不完全多重共线性
公式	$\lambda_1 X_{1i} + \dots + \lambda_k X_{ki} = 0$	$\lambda_1 X_{1i} + \dots + \lambda_k X_{ki} + v_i = 0$
误差项	无，等式精确成立	有 v_i ，等式近似成立
含义	变量间是精确的线性关系	变量间是近似的线性关系
矩阵视角	$\text{Rank}(\mathbf{X}) < k$	$\text{Rank}(\mathbf{X}) = k$ （仍然满秩，但接近不满秩）
现实频率	极少出现	非常常

直觉理解：如果说完全多重共线性像是“用直尺画一条线，所有数据点都精确地落在上面”，那么不完全多重共线性就像是“数据点大致分布在一条线附近，但不是严丝合缝地贴着”。后者的“大致”程度有高有低——越贴近，共线性越严重。

第六步：无多重共线性的含义——一个容易混淆的地方

如果解释变量之间不存在完全的、也不存在不完全的线性关系，则称**无多重共线性**。用矩阵表示，就是 $\mathbf{X}$ 为满秩矩阵，即 $\text{Rank}(\mathbf{X}) = k$ 。

但是——需要特别强调——“解释变量之间不存在线性关系”并不意味着“解释变量之间不存在任何关系”。

如果解释变量之间存在的是**非线性关系**（比如 $X_3 = X_2^2$ ，或者 $X_3 = \sin(X_2)$ ），这**不违反**无多重共线性假定！

暂停理解一下：这个区分很重要。多重共线性关注的是**线性**关系。变量之间可以有各种复杂的非线性关系，只要它们不是（近似）线性的，就不算多重共线性。打个比方：多重共线性检查的是“这些变量是否在同一条直线上（或近似在）”，而不是“这些变量是否有什么联系”。一条抛物线 $y = x^2$ 不是一条直线，所以 x 和 x^2 之间虽然关系密切，但不构成线性共线性。

第七步：三种情形——用相关系数来理解

回归模型中解释变量之间的关系可以表现为以下三种情形：

7.1 情形一： $r_{x_i x_j} = 0$ ——变量间毫无线性关系

解释变量之间完全正交（线性无关）。

- 这是最理想的状况——每个解释变量带来完全独立的信息。
- 但有趣的是，如果变量间真的正交，其实已经不需要做多元回归了。为什么？因为此时每个参数 β_j 都可以通过 Y 对 X_j 的一元回归来估计，结果和多元回归完全一样。
- 这就像：如果每个证人看到的都是完全不同角度的信息，你不需要同时听取所有证人——分别听就行了。

7.2 情形二： $r_{x_i x_j} = 1$ ——完全共线性

解释变量之间存在精确的线性关系。

- 此时模型参数将无法确定。
- **直觉理解：** 当两个变量按完全相同的方式变化时（一个涨，另一个以固定比例跟着涨），你根本无法区分到底是哪个变量在影响 Y 。这就像两个人总是异口同声地说同一句话——你永远无法判断是谁在主导。
- 数学上的表现： $\mathbf{X}'\mathbf{X}$ 矩阵不可逆，OLS 估计量无解。

7.3 情形三： $0 < r_{x_i x_j} < 1$ ——存在一定程度的线性关系

这是实际中最常见的情形。

- 变量之间有某种程度的线性关联，但不是完全的。
- **关键点：** 共线性程度的加强，会给参数估计值的**准确性**和**稳定性**带来影响。
 - 准确性下降：估计值偏离真值更远。
 - 稳定性下降：换一组样本，估计值可能大幅变动。
- 因此，不完全的多重共线性事实上有**严重程度的问题**。 $r = 0.3$ 和 $r = 0.95$ 都是不完全共线性，但后者严重得多。

三种情形的总结图景：

情形	相关系数	含义	对参数估计的影响
正交	$r = 0$	变量完全独立	每个参数可单独估计，无干扰
不完全共线性	$0 < r < 1$	变量有一定线性关联	程度越强，估计越不准、越不稳
完全共线性	$r = 1$	变量精确线性关系	参数完全无法确定

第八步：产生多重共线性的经济背景

多重共线性不是凭空产生的——它有深刻的经济背景。以下是四种常见情形。

8.1 经济变量之间具有共同变化趋势

现象：许多经济变量在经济上升时期一起涨，在经济收缩时期一起跌。

例子：对于时间序列数据，收入、消费、就业率等变量在经济繁荣期都呈现增长趋势，而在经济衰退期又都呈现下降趋势。

为什么会导致共线性？当这些变量同时作为解释变量进入模型时，它们“一起涨、一起跌”的行为使得彼此高度相关。模型很难分辨：到底是收入在影响被解释变量，还是消费在影响？因为它们变动得太同步了。

直觉理解：想象一个合唱团，所有歌手同时唱高音、同时唱低音。如果你只听总声音，你很难判断是哪位歌手的贡献——因为他们的声音完全同步。

8.2 模型中包含滞后变量

现象：当模型中引入了解释变量的滞后变量时，如 X_t, X_{t-1}, X_{t-2} 等。

为什么会导致共线性？一个变量和它自己的滞后值之间常常高度相关。比如，今年的 GDP 和去年的 GDP 高度相关——经济通常不会一年暴涨一年暴跌，而是有惯性。所以 X_t 和 X_{t-1} 之间的相关系数往往非常高，导致多重共线性。

直觉理解：就像今天的温度和昨天的温度——如果昨天 30 度，今天大概率也在 28-32 度之间。两者高度同步，很难区分“今天温度”和“昨天温度”各自对被解释变量（比如空调销量）的独立影响。

8.3 利用截面数据建立模型

现象：使用截面数据（同一时间点上不同个体的数据）建模时，也容易出现共线性。

为什么会导致共线性？在截面数据中，许多变量都与“规模”相关，会呈现出共同增长的趋势。

例子 1：资本、劳动力、科技、能源等投入要素，都与产出规模相关——大企业往往资本多、劳动力多、科技投入多、能源消耗也多。这些变量同涨同跌，导致共线性。

例子 2：粮食产量与化肥用量、水浇地面积、农业投入资金建立回归模型，发现回归效果较差。原因是：农业投入资金的影响已经通过化肥用量和水浇地面积两个因素体现出来了——投入资金多→买化肥多→水浇地面积大。所以这三个解释变量之间高度相关，资金的信息已经被另外两个变量“吸收”了。

直觉理解：就像一个人的身高、体重、鞋码——它们都与“体型大小”有关。如果你同时用身高、体重、鞋码来预测某人的力气大小，其中很多信息是重复的，因为个子高的人通常也重、脚也大。

8.4 样本数据自身的原因

现象：有时候多重共线性不是经济规律导致的，而是数据本身的问题。

具体情形：

- **抽样范围有限：** 如果抽样仅仅限于总体中解释变量取值的一个有限范围，使得变量的变异不大（即变量值都差不多），就容易产生共线性。比如只调查收入在 5 万到 6 万之间的人群，收入几乎不变，它和其他变量的关系就会被“压缩”在很小的范围内，显得模糊不清。
 - **总体受限：** 由于总体本身受限，多个解释变量的样本数据之间相关。比如只研究某个小行业的企业，这些企业规模相近、经营模式相似，很多变量自然高度相关。
- 直觉理解：** 就像你只用红色和橙色的颜料来画画——因为颜色太接近，你很难画出层次分明的效果。数据的“颜色”太接近（变异太小），也会让变量之间的关系难以区分。

总结

整篇文章的逻辑链条如下：

1. **统一格式：** 把截距项也看作解释变量的系数，使模型形式统一。
2. **定义完全共线性：** 存在不全为零的 λ ，使得 λ 的线性组合精确为零——变量间存在精确的线性关系。
3. **矩阵视角：** 完全共线性等价于数据矩阵 $\mathbf{X}$ 的秩小于 k （不满秩）。
4. **定义不完全共线性：** 线性组合加上随机扰动项 v_i 后等于零——变量间是近似线性关系，这是实际中最常见的。
5. **澄清误区：** 无多重共线性只排除线性关系，不排除非线性关系。
6. **三种情形：** $r = 0$ （正交，理想但罕见）、 $r = 1$ （完全共线，参数不可估）、 $0 < r < 1$ （不完全共线，有严重程度之分）。
7. **经济背景：** 共同趋势、滞后变量、截面数据的规模效应、样本局限——这四类是多重共线性的主要来源。