

多重共线性产生的后果——极详细推导与讲解

引言

本文以初学者能跟上的细致程度，推导和讲解“多重共线性”对回归分析造成的全部后果。内容分为两大部分：**完全多重共线性的后果**和**不完全多重共线性的后果**。每一步代数变形、每一个直觉理解、每一个公式背后的“为什么”都给出解释，绝不存在跳步。

1 超级基础的准备知识

0.1 我们在研究什么问题？

在多元线性回归中，我们用多个解释变量（X）来解释一个被解释变量（Y）。比如，用“工业增加值”和“居民消费”两个变量来解释“财政收入”。

一个自然的问题：如果两个解释变量之间本身就存在很强的线性关系（比如工业增加值和居民消费几乎同步增长），会出什么问题？

这就是“多重共线性”要讨论的核心。

0.2 什么是多重共线性？

- **直观说法：**解释变量之间“彼此长得太像”，一个变量几乎可以用另一个变量乘上一个常数来表示。
- **严格说法：**如果某个解释变量可以由其他解释变量**精确地**线性表示，就叫做“完全多重共线性”；如果只是**近似地**线性表示，就叫做“不完全多重共线性”。

0.3 本文使用的模型

为了具体说明问题，我们始终以**两个解释变量的回归模型**为例：

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i \quad (0.1)$$

其中：

- Y_i : 第 i 个观测的被解释变量。
- X_{2i} : 第 i 个观测的第一个解释变量。
- X_{3i} : 第 i 个观测的第二个解释变量。
- β_1 : 截距项（常数项）。
- β_2 : X_2 对 Y 的偏回归系数——含义是“在 X_3 不变的条件下， X_2 每变动1单位， Y 平均变动 β_2 单位”。
- β_3 : X_3 对 Y 的偏回归系数——含义是“在 X_2 不变的条件下， X_3 每变动1单位， Y 平均变动 β_3 单位”。
- u_i : 随机误差项。

0.4 离差形式

为了推导方便，我们把模型写成离差形式。令：

- $y_i = Y_i - \bar{Y}$ (Y 的离差)
- $x_{2i} = X_{2i} - \bar{X}_2$ (X_2 的离差)
- $x_{3i} = X_{3i} - \bar{X}_3$ (X_3 的离差)

离差形式的回归模型为：

$$y_i = \beta_2 x_{2i} + \beta_3 x_{3i} + (u_i - \bar{u}) \quad (4.4)$$

暂停理解一下：离差形式的好处是消去了截距项 β_1 ，使得公式更简洁。原来的模型有3个参数 $(\beta_1, \beta_2, \beta_3)$ ，离差形式只有2个 (β_2, β_3) ，计算更方便。

0.5 离差的重要性质

$$\sum_{i=1}^n x_{2i} = \sum_{i=1}^n (X_{2i} - \bar{X}_2) = \sum X_{2i} - n\bar{X}_2 = n\bar{X}_2 - n\bar{X}_2 = 0 \quad (1)$$

同理 $\sum x_{3i} = 0$ ， $\sum y_i = 0$ 。这个性质后面会反复用到。

0.6 OLS估计量的方差公式来源

在多元回归中，参数估计量的方差-协方差矩阵为：

$$\text{Var-Cov}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (2)$$

这个公式告诉我们：参数估计量的精度取决于 $(\mathbf{X}'\mathbf{X})^{-1}$ 这个矩阵。如果这个逆矩阵出了问题（不存在、或者元素很大），估计量就出问题了。多重共线性的所有后果，本质上都源于这个逆矩阵出了问题。

2 第一部分：完全多重共线性产生的后果

后果1：参数的估计值不确定

目标：证明当 X_2 和 X_3 完全共线性时（即 $X_{2i} = \lambda X_{3i}$ ），OLS估计量 $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 变成 $0/0$ 的不定式，无法确定。

第一步：回顾OLS估计公式

由第三章的结果，对离差形式的模型 $y_i = \beta_2 x_{2i} + \beta_3 x_{3i} + (u_i - \bar{u})$ ，其OLS估计量为：

$$\hat{\beta}_2 = \frac{(\sum y_i x_{2i})(\sum x_{3i}^2) - (\sum y_i x_{3i})(\sum x_{2i} x_{3i})}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i} x_{3i})^2} \quad (4.5)$$

$$\hat{\beta}_3 = \frac{(\sum y_i x_{3i})(\sum x_{2i}^2) - (\sum y_i x_{2i})(\sum x_{2i} x_{3i})}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i} x_{3i})^2} \quad (4.6)$$

暂停理解一下：这两个公式的分母是完全一样的！都是 $(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i} x_{3i})^2$ 。记住这一点，后面会反复用到。

第二步：引入完全共线性条件

现在假设 X_2 和 X_3 完全共线性，即存在一个非零常数 λ ，使得：

$$X_{2i} = \lambda X_{3i} \quad \text{对所有 } i$$

这意味着什么呢？ X_2 不过是 X_3 的一个固定倍数。比如，如果 X_2 是“以厘米衡量的身高”， X_3 是“以米衡量的身高”，那么 $X_2 = 100X_3$ （ $\lambda = 100$ ）。它们本质上是同一个信息！

既然 $X_{2i} = \lambda X_{3i}$ ，那么离差之间也满足同样的关系：

$$x_{2i} = X_{2i} - \bar{X}_2 = \lambda X_{3i} - \lambda \bar{X}_3 = \lambda(X_{3i} - \bar{X}_3) = \lambda x_{3i}$$

所以： $x_{2i} = \lambda x_{3i}$ 。

第三步：将 $x_{2i} = \lambda x_{3i}$ 代入分子和分母

先处理分母（两个公式共用）：

$$\text{分母} = (\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2$$

把 $x_{2i} = \lambda x_{3i}$ 代入：

- $\sum x_{2i}^2 = \sum (\lambda x_{3i})^2 = \lambda^2 \sum x_{3i}^2$
- $\sum x_{2i}x_{3i} = \sum (\lambda x_{3i})(x_{3i}) = \lambda \sum x_{3i}^2$

所以分母变成：

$$\text{分母} = (\lambda^2 \sum x_{3i}^2)(\sum x_{3i}^2) - (\lambda \sum x_{3i}^2)^2$$

展开：

$$\begin{aligned} &= \lambda^2 (\sum x_{3i}^2)(\sum x_{3i}^2) - \lambda^2 (\sum x_{3i}^2)^2 \\ &= \lambda^2 (\sum x_{3i}^2)^2 - \lambda^2 (\sum x_{3i}^2)^2 = 0 \end{aligned}$$

分母等于0！ 这意味着无论分子是什么，整个分数都没有意义。

再处理 $\hat{\beta}_2$ 的分子：

$$\text{分子} = (\sum y_i x_{2i})(\sum x_{3i}^2) - (\sum y_i x_{3i})(\sum x_{2i} x_{3i})$$

把 $x_{2i} = \lambda x_{3i}$ 代入：

- $\sum y_i x_{2i} = \sum y_i (\lambda x_{3i}) = \lambda \sum y_i x_{3i}$
- $\sum x_{2i} x_{3i} = \lambda \sum x_{3i}^2$ （刚才算过了）

所以分子变成：

$$\begin{aligned} &(\lambda \sum y_i x_{3i})(\sum x_{3i}^2) - (\sum y_i x_{3i})(\lambda \sum x_{3i}^2) \\ &= \lambda (\sum y_i x_{3i})(\sum x_{3i}^2) - \lambda (\sum y_i x_{3i})(\sum x_{3i}^2) \\ &= 0 \end{aligned}$$

分子也等于0！

因此：

$$\hat{\beta}_2 = \frac{0}{0} \tag{4.7}$$

这是一个不定式——0/0 可以等于任何数，完全无法确定。

再处理 $\hat{\beta}_3$ 的分子：

$$\text{分子} = (\sum y_i x_{3i})(\sum x_{2i}^2) - (\sum y_i x_{2i})(\sum x_{2i} x_{3i})$$

把 $x_{2i} = \lambda x_{3i}$ 代入：

- $\sum x_{2i}^2 = \lambda^2 \sum x_{3i}^2$
- $\sum y_i x_{2i} = \lambda \sum y_i x_{3i}$
- $\sum x_{2i} x_{3i} = \lambda \sum x_{3i}^2$

所以分子变成：

$$\begin{aligned} & (\sum y_i x_{3i})(\lambda^2 \sum x_{3i}^2) - (\lambda \sum y_i x_{3i})(\lambda \sum x_{3i}^2) \\ &= \lambda^2 (\sum y_i x_{3i})(\sum x_{3i}^2) - \lambda^2 (\sum y_i x_{3i})(\sum x_{3i}^2) \\ &= 0 \end{aligned}$$

分子又是0！ 所以：

$$\hat{\beta}_3 = \frac{0}{0} \quad (4.8)$$

同样是不定式。

第四步：直觉理解——为什么估计值会不确定？

回忆一下 $\hat{\beta}_2$ 的含义：在 X_3 保持不变的条件下， X_2 每变动1单位， Y 平均变动多少。

但现在 X_2 和 X_3 完全绑在一起了 ($X_2 = \lambda X_3$)。你根本不可能做到“让 X_2 变而 X_3 不变”——因为 X_2 一变， X_3 必然跟着变！

比喻：假设你要研究“左手力气”和“右手力气”哪个对“举重成绩”影响更大。但数据中所有运动员的左右手力气完全成比例（左手力气 = 2 × 右手力气）。那你根本无法区分：到底是左手还是右手在起作用？因为它们永远一起变，你找不到“右手力气变了但左手力气没变”的情况。两个变量的影响被彻底绑死了，无法分开。

从矩阵角度理解：OLS估计需要计算 $(\mathbf{X}'\mathbf{X})^{-1}$ 。完全共线性时， $\mathbf{X}$ 矩阵的列线性相关， $\mathbf{X}'\mathbf{X}$ 的行列式为0，逆矩阵不存在。正规方程组的解不唯一——就像方程组 $x + y = 5$ 和 $2x + 2y = 10$ 一样，两个方程其实说的是同一件事，有无穷多组解。

后果2：参数估计值的方差无限大

目标：证明当 X_2 和 X_3 完全共线性时， $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 的方差趋向无穷大。

第一步：回顾方差公式

由第三章，两个解释变量模型中 $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 的方差为：

$$\text{Var}(\hat{\beta}_2) = \frac{\sum x_{3i}^2}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2} \sigma^2 \quad (4.9)$$

$$\text{Var}(\hat{\beta}_3) = \frac{\sum x_{2i}^2}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2} \sigma^2 \quad (4.10)$$

注意：这两个方差公式的分母与前面估计量公式的分母完全一样！都是 $(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2$ 。

第二步：代入完全共线性条件

已知 $x_{2i} = \lambda x_{3i}$ ，且我们已算出：

- $\sum x_{2i}^2 = \lambda^2 \sum x_{3i}^2$
- $\sum x_{2i}x_{3i} = \lambda \sum x_{3i}^2$

代入 $\text{Var}(\hat{\beta}_2)$ 的分母：

$$\begin{aligned} (\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2 &= (\lambda^2 \sum x_{3i}^2)(\sum x_{3i}^2) - (\lambda \sum x_{3i}^2)^2 \\ &= \lambda^2 (\sum x_{3i}^2)^2 - \lambda^2 (\sum x_{3i}^2)^2 = 0 \end{aligned}$$

分母为0！所以：

$$\text{Var}(\hat{\beta}_2) = \frac{\sum x_{3i}^2}{0} \sigma^2 \rightarrow \infty$$

同理， $\text{Var}(\hat{\beta}_3)$ 的分母也是0：

$$\text{Var}(\hat{\beta}_3) = \frac{\lambda^2 \sum x_{3i}^2}{0} \sigma^2 \rightarrow \infty$$

第三步：直觉理解——方差无穷大意味着什么？

方差衡量的是估计量的“波动程度”。方差无穷大，意味着：每次抽不同的样本，算出来的 $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 可能是天差地别的值——可能很大、可能很小、可能是正的、可能是负的，完全没有稳定性。

比喻：想象一个温度计，每次量同一个温度，读数却在上蹿下跳——有时显示零上50度，有时显示零下30度。这个温度计的“方差”就极大，根本不可信。完全共线性下的OLS估计量就是这样一个“坏温度计”。

3 第二部分：不完全多重共线性产生的后果

完全共线性 ($X_2 = \lambda X_3$) 是一种极端情况，现实中几乎不会出现。更常见的情况是不完全共线性—— X_2 和 X_3 之间有很强的近似线性关系，但不是完全的。此时 $(X'X)^{-1}$ 存在，参数可以估计出来，但会带来一系列问题。

后果1：参数估计值的方差与协方差增大

目标：推导出不完全共线性下， $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 的方差如何随共线性程度增大而增大，最终引入方差膨胀因子 (VIF)。

第一步：设定不完全共线性关系

不完全共线性意味着 X_2 和 X_3 之间有近似线性关系，但不完全。用离差形式表示为：

$$x_{2i} = \lambda x_{3i} + v_i \quad (4.11)$$

其中：

- $\lambda \neq 0$ ：一个非零常数。
- v_i ：随机误差项，表示 x_{2i} 不能被 λx_{3i} 完全解释的那部分。

关键性质： $\sum x_{3i} v_i = 0$ 。这个条件的含义是： v_i 与 x_{3i} 不相关。换句话说， x_{2i} 中能被 x_{3i} 线性解释的部分都归入了 λx_{3i} ，剩余的部分 v_i 与 x_{3i} 正交（垂直）。

暂停理解一下：对比完全共线性和不完全共线性——

- 完全共线性： $x_{2i} = \lambda x_{3i}$ ，没有 v_i 这一项， x_2 完全由 x_3 决定。
- 不完全共线性： $x_{2i} = \lambda x_{3i} + v_i$ ，多了一个 v_i 。 v_i 就是 x_2 中“不能被 x_3 解释”的那部分独立信息。 v_i 越小，说明 x_2 能被 x_3 解释的部分越多，共线性越严重。

第二步：将不完全共线性代入估计公式

将式(4.11)代入式(4.6)，可以验证 $\hat{\beta}_3$ 仍然是可计算的（因为分母不再为0了）。具体来说，把 $x_{2i} = \lambda x_{3i} + v_i$ 代入后，利用 $\sum x_{3i} v_i = 0$ 化简，得到：

$$\hat{\beta}_3 = \frac{(\sum y_i x_{3i})(\lambda^2 \sum x_{3i}^2 + \sum v_i^2) - (\lambda \sum y_i x_{3i} + \sum v_i y_i)(\lambda \sum x_{3i}^2)}{(\lambda^2 \sum x_{3i}^2 + \sum v_i^2)(\sum x_{3i}^2) - \lambda^2 (\sum x_{3i}^2)^2} \quad (4.12)$$

关键观察：这个分母不再为0了！因为分子多了 $\sum v_i^2$ 项，使得分母中出现了 $(\lambda^2 \sum x_{3i}^2 + \sum v_i^2)(\sum x_{3i}^2) - \lambda^2 (\sum x_{3i}^2)^2 = (\sum v_i^2)(\sum x_{3i}^2) > 0$ 。所以 $\hat{\beta}_3$ 是可以算出来的。

但是：如果 X_2 与 X_3 共线程度越高， v_i 就越小（因为 x_2 越来越接近 λx_3 ， v_i 是剩下的“残余”部分）。当 $v_i \rightarrow 0$ 时，分母趋近于0， $\hat{\beta}_3$ 趋于不确定——也就是向完全共线性的情况靠拢。

第三步：引入相关系数 r_{23}

为了量化“共线性有多严重”，我们使用 X_2 和 X_3 之间的样本相关系数的平方。用离差形式表示：

$$r_{23}^2 = \frac{(\sum x_{2i}x_{3i})^2}{(\sum x_{2i}^2)(\sum x_{3i}^2)} \quad (4.13)$$

暂停理解一下： r_{23}^2 衡量的是 X_2 和 X_3 之间线性关系的强弱。

- $r_{23}^2 = 0$ ： X_2 和 X_3 毫无线性关系，没有共线性。
- $r_{23}^2 = 1$ ： X_2 和 X_3 完全线性相关，完全共线性。
- r_{23}^2 越接近1，共线性越严重。

第四步：推导 $\text{Var}(\hat{\beta}_2)$ 的简化表达式

现在，我们要把式(4.9)中方差的分子用 r_{23}^2 来改写，使得共线性的影响清晰可见。原始公式：

$$\text{Var}(\hat{\beta}_2) = \frac{\sum x_{3i}^2}{(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2} \sigma^2 \quad (4.9)$$

化简步骤（极其详细，无跳步）：

步骤1：观察分母。分母 = $(\sum x_{2i}^2)(\sum x_{3i}^2) - (\sum x_{2i}x_{3i})^2$ 。

步骤2：提取公因子 $(\sum x_{2i}^2)(\sum x_{3i}^2)$ 。也就是把分母写成：

$$(\sum x_{2i}^2)(\sum x_{3i}^2) \left[1 - \frac{(\sum x_{2i}x_{3i})^2}{(\sum x_{2i}^2)(\sum x_{3i}^2)} \right]$$

暂停理解一下：这一步是怎么做的？其实就是把 $a \cdot b - c^2$ 写成 $a \cdot b \cdot (1 - c^2/(ab))$ 。你可以自己验证： $ab(1 - c^2/(ab)) = ab - ab \cdot c^2/(ab) = ab - c^2$ 。没错吧！

步骤3：认出方括号里就是 $1 - r_{23}^2$ ！因为根据式(4.13)：

$$r_{23}^2 = \frac{(\sum x_{2i}x_{3i})^2}{(\sum x_{2i}^2)(\sum x_{3i}^2)}$$

所以分母变成了：

$$(\sum x_{2i}^2)(\sum x_{3i}^2)(1 - r_{23}^2)$$

步骤4：代回方差公式。现在整个方差变为：

$$\text{Var}(\hat{\beta}_2) = \frac{\sum x_{3i}^2}{(\sum x_{2i}^2)(\sum x_{3i}^2)(1 - r_{23}^2)} \sigma^2$$

步骤5：约分。分子有 $\sum x_{3i}^2$ ，分母也有 $\sum x_{3i}^2$ ，约掉：

$$\text{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_{2i}^2(1 - r_{23}^2)} \quad (4.14)$$

第五步：同理推导 $\text{Var}(\hat{\beta}_3)$

用完全对称的方式（分子换为 $\sum x_{2i}^2$ ，约分时约掉 $\sum x_{2i}^2$ ），得到：

$$\text{Var}(\hat{\beta}_3) = \frac{\sigma^2}{\sum x_{3i}^2(1 - r_{23}^2)} \quad (4.15)$$

第六步：推导协方差

类似地，可以推导出：

$$\text{Cov}(\hat{\beta}_2, \hat{\beta}_3) = \frac{-r_{23}\sigma^2}{(1 - r_{23}^2)\sqrt{(\sum x_{2i}^2)(\sum x_{3i}^2)}} \quad (4.16)$$

暂停理解一下：注意协方差前面的负号和 r_{23} 。当 $r_{23} > 0$ （ X_2 和 X_3 正相关）时，协方差为负。直觉上：如果 X_2 和 X_3 同向变动，那么你高估 β_2 的同时往往低估 β_3 ，两个估计量呈反向变动，协方差为负。

第七步：关键观察—— r_{23}^2 越大，方差越大

现在看式(4.14)和(4.15)，分母中都有 $(1 - r_{23}^2)$ 这一项。

- 如果 $r_{23}^2 = 0$ （无共线性）：分母中的 $(1 - 0) = 1$ ，方差就是 $\sigma^2 / \sum x_{2i}^2$ ，这是“正常的”方差。
- 如果 $r_{23}^2 = 0.5$ ： $(1 - 0.5) = 0.5$ ，方差变为无共线性时的 $1/0.5 = 2$ 倍。
- 如果 $r_{23}^2 = 0.9$ ： $(1 - 0.9) = 0.1$ ，方差变为 $1/0.1 = 10$ 倍！
- 如果 $r_{23}^2 = 0.99$ ： $(1 - 0.99) = 0.01$ ，方差变为 $1/0.01 = 100$ 倍！！
- 如果 $r_{23}^2 \rightarrow 1$ ： $(1 - r_{23}^2) \rightarrow 0$ ，方差 $\rightarrow \infty$ ——回到了完全共线性的结果。

比喻： $(1 - r_{23}^2)$ 就像是水管的水压。 r_{23}^2 越大，水管越窄（水压越低），方差（用水困难程度）就越大。当水管完全堵死（ $r_{23}^2 = 1$ ），水完全流不过去（方差无穷大）。

第八步：引入方差膨胀因子（VIF）

为了更直观地衡量共线性对方差的影响，我们定义方差膨胀因子（Variance Inflation Factor, VIF）：

$$\text{VIF} = \frac{1}{1 - r_{23}^2} \quad (4.17)$$

为什么叫“膨胀因子”？因为它衡量的是：由于共线性的存在，方差“膨胀”了多少倍。

- 当 $r_{23}^2 = 0$ （无共线性）： $\text{VIF} = 1/(1 - 0) = 1$ 。方差没有膨胀。
- 当 $r_{23}^2 = 0.9$ ： $\text{VIF} = 1/0.1 = 10$ 。方差膨胀了10倍。
- 当 $r_{23}^2 = 0.99$ ： $\text{VIF} = 1/0.01 = 100$ 。方差膨胀了100倍！
- 当 $r_{23}^2 \rightarrow 1$ ： $\text{VIF} \rightarrow \infty$ 。方差膨胀到无穷大。

用VIF重写方差公式：

$$\text{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_{2i}^2} \times \text{VIF} \quad (4.18)$$

$$\text{Var}(\hat{\beta}_3) = \frac{\sigma^2}{\sum x_{3i}^2} \times \text{VIF} \quad (4.19)$$

极其重要的结论： $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 的方差与VIF成正比。VIF越大，方差越大，估计越不精确。

暂停理解一下： $\sigma^2 / \sum x_{2i}^2$ 是什么？它是在没有共线性（ $r_{23}^2 = 0$ ）时 $\hat{\beta}_2$ 的“基准方差”。而VIF就是这个基准方差被“放大”的倍数。所以VIF就是“膨胀倍数”。

后果2：置信区间扩大

目标：说明共线性如何使得参数的置信区间变宽，降低估计精度。

第一步：回顾置信区间的构造

β_3 的95%置信区间为：

$$\hat{\beta}_3 \pm 1.96 \sqrt{\text{Var}(\hat{\beta}_3)}$$

其中1.96是标准正态分布在95%置信度下的双侧分位数。

将式(4.15)代入：

$$\hat{\beta}_3 \pm 1.96 \sqrt{\frac{\sigma^2}{\sum x_{3i}^2 (1 - r_{23}^2)}} = \hat{\beta}_3 \pm 1.96 \sqrt{\frac{\sigma^2}{\sum x_{3i}^2}} \times \frac{1}{\sqrt{1 - r_{23}^2}}$$

注意 $\frac{1}{\sqrt{1 - r_{23}^2}} = \sqrt{\text{VIF}}$ 。所以置信区间的半宽度（即 $\pm$ 后面的部分）与 $\sqrt{\text{VIF}}$ 成正比！

暂停理解一下：置信区间越窄，我们对参数真实值的定位越精确；越宽，越不确定。共线性通过增大VIF，使得置信区间变宽，我们就像在更大范围内“瞎猜”参数在哪里。

第二步：表4.1的数值演示

书中的表4.1给出了不同 r_{23} 下 β_3 的95%置信区间：

表 1: 表4.1 不同 r_{23} 下 β_3 的95%置信区间

r_{23}	r_{23}^2	VIF	β_3 的95%置信区间	相对于无共线性的宽度倍数
0.00	0.00	1	$\hat{\beta}_3 \pm 1.96 \sqrt{\sigma^2 / \sum x_{3i}^2}$	1倍
0.50	0.25	1.33	$\hat{\beta}_3 \pm 1.96 \sqrt{1.33\sigma^2 / \sum x_{3i}^2}$	$\sqrt{1.33} \approx 1.15$ 倍
0.99	0.9801	50.25	$\hat{\beta}_3 \pm 1.96 \sqrt{50\sigma^2 / \sum x_{3i}^2}$	$\sqrt{50} \approx 7.07$ 倍
0.999	0.998001	500.25	$\hat{\beta}_3 \pm 1.96 \sqrt{500\sigma^2 / \sum x_{3i}^2}$	$\sqrt{500} \approx 22.4$ 倍

逐行解释：

- $r_{23} = 0$ ：没有共线性， $\text{VIF} = 1$ ，这是“正常的”置信区间宽度。
- $r_{23} = 0.50$ ： $\text{VIF} = 1/(1 - 0.25) = 1/0.75 \approx 1.33$ 。方差只膨胀了1.33倍，置信区间宽度约为原来的1.15倍——影响不大。
- $r_{23} = 0.99$ ： $\text{VIF} = 1/(1 - 0.9801) = 1/0.0199 \approx 50.25$ 。方差膨胀了50倍！置信区间宽度约为原来的 $\sqrt{50} \approx 7$ 倍——影响巨大！
- $r_{23} = 0.999$ ： $\text{VIF} \approx 500$ 。方差膨胀了500倍！置信区间宽度约为原来的 $\sqrt{500} \approx 22$ 倍——完全不可用了！

比喻：你在玩飞镖。无共线性时，你大概能扎在靶心附近（小置信区间）。 $r_{23} = 0.99$ 时，就像蒙着眼睛转了7圈再扔飞镖——飞镖可能扎到靶上任何地方（大置信区间）。 $r_{23} = 0.999$ 时，你不仅蒙着眼睛转了22圈，还被人扛到了另一个房间——飞镖可能扎到墙上、天花板上，完全不可控。

后果3：假设检验容易做出错误的判断

目标：说明共线性如何导致t检验失效——本应显著的变量被误判为不显著。

第一步：t检验的统计量

对回归系数的原假设 $H_0: \beta_3 = 0$ 进行检验时，使用t统计量：

$$t = \frac{\hat{\beta}_3}{\sqrt{\text{Var}(\hat{\beta}_3)}}$$

暂停理解一下：t值的含义是“估计值是标准误的几倍”。t值越大，说明估计值相对于其波动幅度而言“很大”，越有理由认为 β_3 不是0（即 X_3 对 Y 有显著影响）。

第二步：共线性如何影响t值

由式(4.15)：

$$\text{Var}(\hat{\beta}_3) = \frac{\sigma^2}{\sum x_{3i}^2 (1 - r_{23}^2)}$$

当 r_{23}^2 增大时， $(1 - r_{23}^2)$ 减小， $\text{Var}(\hat{\beta}_3)$ 增大， $\sqrt{\text{Var}(\hat{\beta}_3)}$ 也增大。
现在看t值：

$$t = \frac{\hat{\beta}_3}{\sqrt{\text{Var}(\hat{\beta}_3)}}$$

分母变大，t值变小。

第三步：t值变小会导致什么？

t检验的判断规则是：如果 $|t|$ 大于临界值（比如1.96），就拒绝 $H_0: \beta_3 = 0$ ，认为 X_3 对 Y 有显著影响。

但共线性使得t值变小。原本 $|t|$ 应该大于1.96（ X_3 确实有影响），现在却因为共线性导致t值缩小到1.96以下，于是我们**错误地**接受了“ $\beta_3 = 0$ ”的原假设。

比喻：你在法庭上想证明某人有罪。证据（ $\hat{\beta}_3$ ）确实指向他有罪，但因为你对证据的“不确定性”太大（方差太大、标准误太大），法官说“证据不够确凿”，放了他。实际上他是有罪的，只是共线性干扰了你的判断。

双重打击：

1. 置信区间扩大 → 更容易接受本应拒绝的假设（第一类错误的风险变化）。
2. t值变小 → 更容易错误地接受“ $\beta = 0$ ”的原假设（第二类错误增大）。

后果4： R^2 高但 t 检验不显著——最令人困惑的现象

目标：解释为什么会出现“整体方程很显著，但单个变量都不显著”的矛盾现象。

第一步：矛盾现象描述

在存在严重多重共线性时，常常出现以下情况：

- R^2 很高：模型的拟合优度很好，解释变量“集体”对 Y 的解释力很强。
- F 检验显著：联合检验拒绝“所有系数都为0”的原假设，说明解释变量整体对 Y 有显著影响。
- 但个别 t 检验不显著：对 β_2 和 β_3 分别做 t 检验，却都接受“ $\beta = 0$ ”的原假设。
- 甚至系数符号反常：比如经济理论上 β_2 应该为正，但估计出来却是负的。

第二步：为什么会出现这种矛盾？

直觉解释：

- R^2 高、 F 检验显著，说明 X_2 和 X_3 合在一起确实能很好地解释 Y 。这没问题——因为它们的信息总量是够的。
- 但 t 检验不显著，是因为我们无法单独区分 X_2 和 X_3 各自的贡献。它们的信息高度重叠，就像两个人紧挨着站在一起，你能看到“有人在那”，但分不清谁是谁。
- 系数符号反常，是因为共线性导致估计值极不稳定。就像温度计坏了一样，它可能给你一个完全相反的读数。

比喻：两个歌手合唱一首歌，合唱效果非常好（ R^2 高），但你听不出每个人唱了多大声——因为他们的声音几乎完全同步（ t 检验不显著）。甚至有时候因为回声干扰，你误以为其中一个人在唱反调（系数符号反常）。

第三步：教材中的实例

教材提到了一个典型例子：“工业增加值增长会减少财政收入吗？”

正常情况下，工业增加值增长，财政收入应该增加（ β 应该为正）。但由于工业增加值与其他解释变量之间存在严重共线性，回归结果中工业增加值的系数竟然为负——这在经济学上完全说不通。这正是多重共线性导致的“系数符号反常”现象。

遇到这种情况时：如果发现回归方程整体很显著（ R^2 高、 F 检验通过），但个别系数 t 检验不显著、甚至符号与经济理论矛盾，首先应该怀疑的就是多重共线性。

4 总结：多重共线性的全部后果一览

严重的多重共线性常常导致以下情形出现：

1. **估计值不稳定**：用OLS得到的回归参数估计值很不稳定，换一个样本可能得到完全不同的结果。

2. **方差与协方差加速增长**：回归系数的方差与协方差随着多重共线性强度的增加而加速增长（不是线性增长，而是通过VIF的机制加速膨胀），对参数难以做出精确的估计。

3. **整体显著但个别不显著**：造成回归方程高度显著（ R^2 高、 F 检验通过）的情况下，有些回归系数却通不过显著性检验（ t 检验不通过）。

4. **系数符号反常**：甚至可能出现回归系数的正负号得不到合理的经济解释。

但是——有一个重要的例外：如果研究目的仅在于预测 Y ，而且各个解释变量 X 之间的多重共线性关系的性质在未来将继续保持，这时虽然无法精确估计个别的回归系数，但可以估计这些系数的某些线性组合，因此多重共线性可能并不是严重问题。

暂停理解一下这最后一条：为什么预测时共线性不是大问题？因为预测只关心 $\hat{Y} = \hat{\beta}_1 + \hat{\beta}_2 X_2 + \hat{\beta}_3 X_3$ 这个整体，而不关心 $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 各自是多少。虽然 $\hat{\beta}_2$ 和 $\hat{\beta}_3$ 各自不稳定，但它们“此消彼长”（协方差为负），加在一起的效果可能是稳定的——只要 X_2 和 X_3 之间的关系在未来保持不变。

比喻：你要预测明天的天气，用“温度计A”和“温度计B”两个指标。虽然这两个指标高度相关，你分不清各自对天气预测的独立贡献，但只要它们的相关关系不变，你用它们一起预测天气的效果仍然很好——只是你无法说“温度计A贡献了60%，温度计B贡献了40%”。

整篇文章的逻辑链条：

1. **完全共线性**：OLS估计量的分母为0 $\rightarrow$ 估计值不确定（0/0）；方差公式的分母也为0 $\rightarrow$ 方差无穷大。核心原因：两个变量提供的是完全相同的信息，无法区分各自的贡献。
2. **不完全共线性**：估计量可以计算，但共线性越强（ r_{23}^2 越大），VIF越大 $\rightarrow$ 方差越大 $\rightarrow$ 置信区间越宽 $\rightarrow$ t 值越小 $\rightarrow$ 假设检验越容易犯错 $\rightarrow$ 可能出现“整体显著但个别不显著”甚至“系数符号反常”的矛盾现象。
3. **例外情况**：如果目的只是预测，且共线性结构未来保持，则多重共线性不是大问题。

希望这样的讲解能够让你完全明白每一步是在做什么、为什么这样做。