

多重共线性的检验——极详细讲解

引言

本文以初学者能完全跟上的细致程度，逐步讲解回归模型中“多重共线性”的四种检验方法。每一种方法的思想从何而来、公式怎么来的、怎么用、有什么局限，全部交代清楚，绝不存在跳步。

第零步：先回顾——什么是多重共线性？我们为什么要检验它？

在多元线性回归模型中，我们有好几个解释变量 $X_1, X_2, \dots, X_k$ 。这些变量本来应该是各自独立地帮助解释 Y 的。但是，如果某些解释变量之间存在高度的线性相关关系（比如 X_1 几乎可以用 X_2 线性表示），就出现了“多重共线性”问题。

多重共线性的危害（这是为什么我们要检验它）：

- 参数估计量的方差变得非常大（估计值不稳定，换一组数据就大变样）
- 系数的符号可能反常（本来该是正的，算出来却是负的）
- 重要变量通不过显著性检验（ t 检验不显著）

所以，我们**必须**在建模之后检验多重共线性是否存在。下面介绍四种方法。

第一步：简单相关系数检验法——最直觉的方法

1.1 核心思想

如果两个解释变量之间的线性相关程度很高，那它们就“长得很像”，其中一个就是“多余”的——这就是多重共线性。那我们自然想到：直接算一算每两个解释变量之间的相关系数，看它有多大不就行了吗？

这就是简单相关系数检验法。

1.2 什么是简单相关系数（零阶相关系数）？

对于任意两个解释变量 X_i 和 X_j ，它们之间的简单相关系数定义为：

$$r_{X_i, X_j} = \frac{\sum (X_i - \bar{X}_i)(X_j - \bar{X}_j)}{\sqrt{\sum (X_i - \bar{X}_i)^2 \cdot \sum (X_j - \bar{X}_j)^2}} \quad (1)$$

逐项解释：

- 分子：两个变量离差的乘积之和。如果 X_i 和 X_j 同涨同跌，乘积为正，加起来就大；如果一个涨一个跌，乘积为负，会抵消。
- 分母：各自离差平方和的乘积再开根号。这是为了“标准化”，让相关系数的取值范围固定在 $[-1, 1]$ 之间。

为什么叫“零阶”相关系数？因为它只看两个变量之间的直接关联，没有控制其他变量的影响（即偏相关系数中的“阶”为零）。

1.3 判断标准

经验法则：如果两个解释变量的简单相关系数 $|r| > 0.8$ ，就可以认为存在较严重的多重共线性。

为什么选 0.8？因为 0.8 意味着两个变量之间有 64% ($0.8^2 = 0.64$) 的变动是可以互相“解释”的。也就是说，一个变量 64% 的信息已经被另一个变量包含了，留下来的独立信息只有 36%，这就太少了。

1.4 重大局限——高相关系数只是充分条件，不是必要条件

这句话极其重要，很多人搞反。让我仔细解释：

充分条件的意思：如果 $r > 0.8$ ，那多重共线性一定存在。→ 这没问题，两个变量高度相关，当然共线。

不是必要条件的意思：即使所有两两之间的 r 都不高（比如都小于 0.5），多重共线性仍然可能存在！

为什么？一个关键例子：

假设我们有三个解释变量 X_1, X_2, X_3 。它们之间的关系是：

$$X_3 = 0.6X_1 + 0.6X_2$$

这时候， X_1 和 X_2 之间的相关系数可能只有 0.3（不高）， X_1 和 X_3 之间大约 0.7， X_2 和 X_3 之间大约 0.7。没有任何一对超过 0.8。但是！ X_3 几乎完全被 X_1 和 X_2 的线性组合决定了， R_3^2 （ X_3 对 X_1, X_2 回归的可决系数）接近 1——多重共线性非常严重！

所以：简单相关系数法只能捕捉“两两之间”的高相关，但无法发现“三个或更多变量联合起来”的共线性。这就是它的盲区。

1.5 小结

优点	缺点
简单直观，容易操作	只能发现两两共线性，遗漏“联合共线性”
计算方便，任何统计软件都能做	$r > 0.8$ 是充分条件而非必要条件

第二步：方差扩大（膨胀）因子法——最常用的方法

2.1 核心思想

简单相关系数只看“两两关系”，有盲区。那我们换一个思路：对于每一个解释变量，看看它被其他所有解释变量“联合解释”的程度有多大。如果某个变量几乎完全被其他变量决定了，那这个变量就是“多余的”——存在多重共线性。

这就是方差扩大因子（Variance Inflation Factor，简称 VIF）法的思路。

2.2 什么是辅助回归？

假设我们有 k 个解释变量 $X_1, X_2, \dots, X_k$ 。

对于第 j 个解释变量 X_j ，我们把它当作被解释变量，用其余 $k-1$ 个解释变量来回归它：

$$X_j = \alpha_0 + \alpha_1 X_1 + \dots + \alpha_{j-1} X_{j-1} + \alpha_{j+1} X_{j+1} + \dots + \alpha_k X_k + v$$

这个回归叫做**辅助回归**——因为它不是为了研究因果关系，而是为了检查 X_j 能不能被其他变量线性表出。

从这个辅助回归，我们可以得到一个**可决系数** R_j^2 。

R_j^2 的含义：其他 $k-1$ 个解释变量联合起来能解释 X_j 变动的百分之多少。

- 如果 R_j^2 接近 1： X_j 几乎完全被其他变量决定了 $\rightarrow$ **严重共线性**
- 如果 R_j^2 接近 0： X_j 基本上是独立的 $\rightarrow$ **没有共线性**

2.3 VIF 公式的推导——它从哪里来？

现在关键问题来了：为什么 R_j^2 和参数估计量的方差有关系？我们来推导。

出发点：在多元线性回归 $Y = \beta_1 + \beta_2 X_2 + \dots + \beta_k X_k + u$ 中，第 j 个参数估计量 $\hat{\beta}_j$ 的方差是什么？

我们先看没有共线性时的情况：如果 X_j 和其他解释变量完全无关 ($R_j^2 = 0$)，那么 $\hat{\beta}_j$ 的方差为：

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum x_j^2}$$

逐项解释：

- σ^2 ：随机误差项的方差。误差越大，估计越不精确——这很直觉。
- $\sum x_j^2 = \sum (X_j - \bar{X}_j)^2$ ： X_j 的离差平方和。 X_j 的数据越分散（变化越大），估计越精确——就像你用更多的尺子刻度来量东西，量得更准。

当存在共线性时： X_j 不再是完全独立的了，它的一部分变动被其他变量“分走”了。所以 X_j 真正“属于自己的”有效变动变少了。我们必须对上面的方差公式做一个修正（放大）：

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum x_j^2} \cdot \frac{1}{1 - R_j^2} \quad (4.20)$$

其中多出来的那个因子：

$$\text{VIF}_j = \frac{1}{1 - R_j^2} \quad (4.21)$$

就是方差扩大因子（Variance Inflation Factor）。

2.4 为什么 VIF 会“放大”方差？——极其详细的直觉解释

让我们仔细看看 $\text{VIF}_j = \frac{1}{1 - R_j^2}$ 这个公式在不同情况下的行为：

情况 1：没有共线性 ($R_j^2 = 0$)

$$\text{VIF}_j = \frac{1}{1 - 0} = \frac{1}{1} = 1$$

方差没有被放大。 $\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum x_j^2} \times 1 = \frac{\sigma^2}{\sum x_j^2}$ ，和原来一样。完美！

情况 2：中度共线性 ($R_j^2 = 0.5$)

$$\text{VIF}_j = \frac{1}{1 - 0.5} = \frac{1}{0.5} = 2$$

方差被放大了 2 倍。也就是说，因为 X_j 有一半的变动信息被其他变量占了，估计量的波动（方差）翻了一倍。

情况 3：较严重共线性 ($R_j^2 = 0.9$)

$$\text{VIF}_j = \frac{1}{1 - 0.9} = \frac{1}{0.1} = 10$$

方差被放大了 10 倍！ X_j 有 90% 的变动被其他变量“抢走”了，只剩下 10% 是自己的。用这可怜的 10% 去估计参数，精度当然极差——方差膨胀为原来的 10 倍。

情况 4：几乎完全共线性 ($R_j^2 = 0.99$)

$$VIF_j = \frac{1}{1 - 0.99} = \frac{1}{0.01} = 100$$

方差被放大了 100 倍！估计量几乎完全不可信。

情况 5：完全共线性 ($R_j^2 = 1$)

$$VIF_j = \frac{1}{1 - 1} = \frac{1}{0} \rightarrow \infty$$

方差趋于无穷大！这意味着参数根本无法估计——这和“矩阵不可逆”是同一件事。

类比：想象你和朋友一起去辨认远处的一栋房子。如果只有你一个人看 ($R_j^2 = 0$)，你的判断虽然可能不准，但至少是“你自己的”判断。如果你的朋友已经把 90% 的信息都描述给你了 ($R_j^2 = 0.9$)，你自己能看到的独立信息只剩 10%，你的补充判断就非常不靠谱（方差放大 10 倍）。

2.5 判断标准

经验法则：当 $VIF_j \geq 10$ 时，认为解释变量 X_j 与其余解释变量之间存在严重的多重共线性。

为什么选 10？因为 $VIF_j = 10$ 对应 $R_j^2 = 0.9$ ，也就是说其他变量已经解释了 X_j 的 90% 的变动。 X_j 自己独立的信息只剩 10%，参数估计的方差被放大了 10 倍，通常已经严重影响估计的可靠性了。

有的教材更严格，用 $VIF_j \geq 5$ （对应 $R_j^2 = 0.8$ ）作为警戒线。

2.6 在EViews中的操作

教材提到了EViews软件中VIF的计算方法：

1. **高度共线性时的报错：**当解释变量之间存在完全或高度共线性时，EViews无法给出参数估计结果，会在Equation Specification窗口显示错误提示“near singular matrix”（近似奇异矩阵）。这是因为共线性导致设计矩阵接近不可逆，OLS的矩阵运算 $(X'X)^{-1}$ 无法完成。
2. **计算VIF：**在Equation回归结果窗口中，点击 View $\rightarrow$ Coefficient Diagnostics $\rightarrow$ Variance Inflation Factors，其中**Centered VIF**是最终的VIF结果。

“Centered”意味着在辅助回归中使用了离差形式（减去均值），这与公式(4.21)中的 R_j^2 是一致的。

2.7 VIF 法与简单相关系数法的关键区别

对比项	简单相关系数法	VIF法
考察的对象	两个变量之间的相关	一个变量与所有其他变量联合的相关
能否发现“联合共线性”	不能	能
判断标准	$ r > 0.8$	$VIF \geq 10$
信息的丰富度	只有一组数字（两两之间）	每个变量都有一个VIF值，可以精确定位问题变量

2.8 补充：VIF 公式(4.20)的更深层理解

公式(4.20)其实是公式(4.17)（两变量情况）的自然推广。

在只有两个解释变量 X_2, X_3 的情况中（即教材前文的4.17式）：

$$\text{Var}(\hat{\beta}_2) = \frac{\sigma^2}{\sum x_{2i}^2} \cdot \frac{1}{1 - r_{23}^2}$$

这里 r_{23}^2 就是 X_2 和 X_3 之间的简单相关系数的平方。在两个变量的情况下，辅助回归的可决系数 R_2^2 正好就等于 r_{23}^2 ，因为辅助回归只有一个解释变量。

在有三个及以上解释变量的情况中：

辅助回归有多个解释变量， R_j^2 是多重可决系数，不再等于任何一对简单相关系数的平方。但公式的形式完全一样——只是把 r^2 换成了更一般的 R_j^2 。所以教材说这是“式(4.17)只有两个解释变量情况的拓展”。

第三步：直观判断法——凭经验的“信号”检测

3.1 核心思想

有时候，不用算任何统计量，光看回归结果中的异常现象，就能“嗅出”多重共线性的存在。这就好比医生通过观察病人的症状来初步判断病情——虽然不是精确的诊断，但可以提供重要的线索。

教材给出了四种“异常信号”：

3.2 信号（1）：增删变量或改变观测值时，估计值大幅变化

正常情况下：如果你的模型是稳定的，增加或删除一个不太重要的变量，其他变量的系数估计值应该只发生轻微变化。

共线性时：因为变量之间高度相关，每个变量的系数估计值都是在“互相牵制”中勉强确定的。就像两个紧紧绑在一起的弹簧，你稍微动其中一个，另一个就剧烈弹跳。增删一个变量打破了原有的牵制平衡，导致剩余变量的系数大幅变动。

同理，改变一个观测值（数据点）也会导致类似效果——因为共线性下参数估计对数据极端敏感。

3.3 信号（2）：重要变量的标准误差很大， t 检验不显著

正常情况下：一个理论上重要的解释变量，其系数应该显著不为零。

共线性时：回顾第二步，VIF放大了方差。方差大 $\rightarrow$ 标准误差（方差的平方根）大 $\rightarrow t$ 统计量（系数/标准误差）小 $\rightarrow t$ 检验不显著。

直觉：两个高度相关的变量就像两个抢着做同一件事的人。统计上无法分辨“谁的贡献更大”，所以两个的系数都估计不精确，标准误差都很大。

3.4 信号（3）：系数的正负号与理论预期相反

举例：在消费函数回归中，理论上收入对消费的影响应该是正的（收入越高，消费越多）。但回归结果中收入变量的系数竟然是负的！

原因：共线性导致系数估计值极不稳定，可能在真值附近大幅波动，甚至越过零点变号。这个正负号已经不能反映真实的因果关系了，纯粹是数值拟合的副产物。

3.5 信号（4）：可决系数 R^2 高、 F 检验显著，但重要变量 t 检验不显著

这是最经典的多重共线性信号。让我详细解释为什么会出现这种“矛盾”：

- R^2 高：模型整体拟合得很好——解释变量们联合起来能很好地解释 Y 的变动。
- F 检验显著：从统计上确认了“所有解释变量联合起来对 Y 有显著影响”。
- 但某些重要变量的 t 检验不显著：单独看某个变量，它的系数似乎和零没有显著差异。

这怎么可能？整体显著但个体不显著？

答案就是共线性。因为变量之间高度相关，它们“抱团”一起解释了 Y 的大部分变动（ R^2 高， F 显著），但统计上无法把功劳分配到每个变量头上（每个变量的 t 都不显著）。

类比：三个人一起抬了一张桌子过了门槛（ F 检验显著），但你说不清谁出的力最大——因为他们的力混在一起了（ t 检验都不显著）。

3.6 小结

直观判断法不需要额外计算，只需要观察回归结果中的异常现象。但它只是初步判断，不能替代 VIF 等定量方法。最可靠的做法是：先看信号，再用 VIF 确认。

第四步：逐步回归检测法——有进有出，检测共线性

4.1 核心思想

逐步回归本身是一种变量选择方法，但它的“有进有出”过程恰好可以揭示变量之间的高度相关性——如果两个变量高度相关，引入其中一个后再引入另一个，先前的变量就会因为“多余”而被剔除。

4.2 逐步回归的操作过程（极其详细）

第一步：逐个引入变量

我们把所有候选的解释变量排好队，一个一个地往模型里加。

- 先选与 Y 相关性最强的变量 $X_{(1)}$ ，做一元回归 $Y = \beta_1 + \beta_2 X_{(1)} + u$ 。
- 对这个回归做 F 检验（整体显著性）和 t 检验（ $X_{(1)}$ 的显著性）。如果显著， $X_{(1)}$ 留在模型中。

第二步：引入第二个变量

- 在剩余变量中，选择使回归拟合优度增加最多的变量 $X_{(2)}$ ，加入模型。
- 做回归 $Y = \beta_1 + \beta_2 X_{(1)} + \beta_3 X_{(2)} + u$ 。
- 做 F 检验：新模型整体是否显著？
- 关键步骤：对所有已选入的变量（包括 $X_{(1)}$ ）逐个做 t 检验。
 - 如果 $X_{(1)}$ 仍然显著：两个变量都保留。
 - 如果 $X_{(1)}$ 变得不显著：说明 $X_{(2)}$ 的引入使得 $X_{(1)}$ 变成了“多余的”——这就是多重共线性的信号！此时把 $X_{(1)}$ 剔除。

第三步及之后：反复执行

每次引入一个新变量后：

1. 做 F 检验确认整体显著。
2. 对所有已选入变量重新做 t 检验。

3. 如果有变量因新变量的引入而变得不显著，就剔除它。
4. 如果被剔除的变量在新变量加入后又变显著了，就重新选入。

终止条件：

- 没有新的显著变量可以选入
- 没有不显著的变量需要剔除

此时模型中的变量集就是“最优”的。

4.3 逐步回归为什么能检测多重共线性？

关键在于“有进有出”这个现象。

如果变量之间完全不相关：

- 引入一个变量不会影响其他变量的系数和显著性。
- 已选入的变量永远不会因为新变量的加入而被剔除。
- 没有变量会“有进有出”。

如果变量之间高度相关：

- 引入 $X_{(2)}$ 后， $X_{(1)}$ 的系数和标准误差会剧烈变化（因为共线性放大了方差）。
- $X_{(1)}$ 可能变得不显著，被剔除。
- 如果后来引入的某个变量使 $X_{(1)}$ 的“竞争对手”被剔除， $X_{(1)}$ 又可能重新变得显著，被再次选入。
- 这种“有进有出”的反复现象，就是多重共线性的信号。

类比：一个公司有两个能力几乎一样强的员工（高度相关）。公司只需要一个人做这份工作（模型只需要一个变量）。招了A之后又招了B，发现A变得“多余”了（ t 不显著），就把A裁了。但如果后来B走了，A又变得有价值了。这种反复的“进进出出”说明A和B在做同样的事——他们之间是“共线”的。

4.4 “有怎样程度的相关性才会被剔除”取决于研究目的

教材指出：变量之间相关性达到什么程度才触发“剔除”，取决于研究者的目的和要求。

- 如果目的是**预测精度**：对共线性容忍度高一些，可以保留更多变量。
- 如果目的是**参数估计的准确性和可解释性**：对共线性容忍度低一些，一旦出现“有进有出”，就说明需要处理。

4.5 逐步回归检测法的优缺点

优点	缺点
在选择变量的同时检测共线性	本质上是变量选择方法，不是专门的共线性诊断工具
“有进有出”现象直观易懂	结果可能依赖于变量引入的顺序
可以直接得到“最优”变量子集	每次只看一个变量进出，可能遗漏更复杂的共线性结构

总结：四种方法的比较

方法	检测能力	操作难度	适用场景
简单相关系数法	只能发现两两共线性	最简单	初步筛查，变量少时可用
VIF法	能发现联合共线性	简单	最常用 ，每个变量一个VIF值，精确定位问题
直观判断法	提供信号，非精确诊断	无需额外计算	辅助判断，配合VIF使用
逐步回归法	通过“有进有出”揭示共线性	较复杂	变量选择与共线性检测同时进行

推荐的检验流程：

1. 先看回归结果有没有“异常信号”（直观判断法）
2. 计算每个变量的 VIF 值（VIF法，主力工具）
3. 如果需要同时选择变量，使用逐步回归法
4. 简单相关系数矩阵作为辅助参考