

多重共线性的补救措施——极详细推导与讲解

引言

在前面的学习中，我们已经知道了什么是多重共线性（解释变量之间高度相关），也学会了如何诊断它（方差扩大因子VIF、相关系数矩阵等）。诊断出病，接下来就要治。本文以初学者能跟上的细致程度，逐一讲解降低多重共线性的方法，重点推导岭回归法的数学原理。每一步代数变形、每一个直觉解释、每一个“为什么要这样做”都不省略。

第一步：我们要解决什么问题？

想象一下，你要用一个人的“身高”和“体重”来预测他的“肺活量”。这两个变量（身高和体重）本身就高度相关——个子高的人通常也重。当它们同时出现在回归模型里时，回归系数就会变得极不稳定：今天换几个样本，身高的系数从正的变成负的，体重的系数也飘忽不定。这就是多重共线性带来的麻烦——不是模型完全不能用，而是系数估计不可靠，标准误膨胀，t检验通不过。

我们的目标是：用各种方法降低这种共线性，使得回归系数的估计变得更稳定、更可信。

1 一、修正多重共线性的经验方法

1.1 方法1：剔除变量法

核心思路：既然共线性是因为某些变量“长得太像”引起的，那最直接的办法就是把多余的变量踢出去。

具体操作：当回归方程中存在严重的多重共线性时，可以删除那个引起共线性的、且不太重要的变量。选择删谁时，要综合考虑三个信息：

- 回归系数的显著性检验（t检验的p值大不大？）
- 方差扩大因子VIF（谁的VIF最大，谁就是“罪魁祸首”）
- 经济含义（通过经济学常识判断哪个变量相对不重要）

□**关键警告：**如果你不小心删掉了一个**重要变量**，就会产生**设定误差**（omitted variable bias）。这就像治病时把好细胞也一起杀掉了——共线性虽然消除了，但模型本身变错了，后果可能更严重。

直觉比喻：你去医院查体，发现两个指标高度相关（比如血压和心率）。如果医生只保留一个指标来预测心脏病风险，这可以简化问题；但如果被删掉的那个恰好是更关键的指标，诊断就会出错。

1.2 方法2：增大样本容量

核心思路：多重共线性本质上是**样本特性**，不是总体特性。换一批数据，共线性可能就没那么严重了。所以，尽可能多收集数据。

为什么有效？数学推导如下：

在前面学习方差扩大因子时，我们知道回归系数估计量 $\hat{\beta}_j$ 的方差为：

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum x_i^2} \cdot \text{VIF}_j$$

其中 $\sum x_i^2 = \sum (X_i - \bar{X})^2$ 是解释变量的离差平方和。

现在关键来了：当样本容量 n 增加时， $\sum x_i^2$ 会怎样变化？

- 新增的观测值会带来新的 $(X_i - \bar{X})^2$ 项
- 即使新的观测值恰好等于新平均值， $\sum x_i^2$ 也不会减小（最多保持不变）
- 在大多数实际情况下，新数据会使得 $\sum x_i^2$ 增大

$\sum x_i^2$ 增大 $\rightarrow$ 分母增大 $\rightarrow \text{Var}(\hat{\beta}_j)$ 减小 $\rightarrow$ 标准误减小 $\rightarrow$ 估计更精确

直觉比喻：你用3个人的数据来估计“身高对体重的影响”，碰巧这3个人又高又瘦或又矮又胖，数据很混乱。但如果你收集了300人的数据，里面有各种各样的组合，共线性自然就弱了。

局限性：有些数据（如宏观经济年度数据）很难增加样本量，一年才一个观测值，几十年也就几十个数据点。

1.3 方法3：变换模型形式（差分法）

核心思路：原来的水平值之间高度相关，但如果对数据做一阶差分（本期减上期），差分后的变量之间的相关性通常会大大降低。

数学推导——从水平模型到差分模型：

原始模型（时间序列形式）：

$$Y_t = \beta_0 + \beta_1 X_{1t} + \beta_2 X_{2t} + \cdots + \beta_k X_{kt} + u_t \quad (4.22)$$

其中下标 t 表示第 t 期。

写出第 $t-1$ 期的方程：

$$Y_{t-1} = \beta_0 + \beta_1 X_{1,t-1} + \beta_2 X_{2,t-1} + \cdots + \beta_k X_{k,t-1} + u_{t-1}$$

两式相减（本期减上期）：

$$Y_t - Y_{t-1} = \beta_0 - \beta_0 + \beta_1(X_{1t} - X_{1,t-1}) + \beta_2(X_{2t} - X_{2,t-1}) + \cdots + \beta_k(X_{kt} - X_{k,t-1}) + (u_t - u_{t-1})$$

注意： $\beta_0 - \beta_0 = 0$ ，截距项消失了！

定义差分符号 Δ （读作“delta”），即 $\Delta Y_t = Y_t - Y_{t-1}$ ， $\Delta X_{jt} = X_{jt} - X_{j,t-1}$ ， $\Delta u_t = u_t - u_{t-1}$ ，得到：

$$\Delta Y_t = \beta_1 \Delta X_{1t} + \beta_2 \Delta X_{2t} + \cdots + \beta_k \Delta X_{kt} + \Delta u_t \quad (4.23)$$

为什么差分后共线性会减弱？

举个具体例子： X_1 （GDP）和 X_2 （消费）的水平值高度相关，因为它们都是随时间持续增长的，趋势一致。但 ΔX_1 （GDP的增量）和 ΔX_2 （消费的增量）的相关性就弱得多——有的年份GDP涨得多但消费涨得少，有的年份反过来。

EViews操作：在方程定义栏中输入 $Y-Y(-1) \ X1-X1(-1) \ X2-X2(-1) \ \dots \ Xk-Xk(-1)$ 即可得到 $\beta_1, \beta_2, \dots, \beta_k$ 的估计值。

□**注意事项：**

- 差分会丢失信息（减少一个观测值，即样本从 n 变成 $n-1$ ）
- 差分模型的误差项 $\Delta u_t = u_t - u_{t-1}$ 可能存在**序列相关**，违背了经典假设
- 因此，差分法虽然降低了共线性，但可能引入新的问题，使用时要慎重

1.4 方法4：利用非样本先验信息

核心思路：如果经济学理论告诉我们某个参数是另一个参数的某个倍数，我们就可以利用这个约束来减少需要估计的参数个数，从而缓解共线性。

数学推导：

原模型：

$$Y_t = \beta_1 + \beta_2 X_{2t} + \beta_3 X_{3t} + u_t \quad (4.24)$$

假设依据长期经验分析，我们知道 $\beta_3 = 0.2\beta_2$ 。

这一步怎么用的？我们把 $\beta_3 = 0.2\beta_2$ 代入原模型：

$$Y_t = \beta_1 + \beta_2 X_{2t} + 0.2\beta_2 X_{3t} + u_t$$

把含 β_2 的项合并：

$$Y_t = \beta_1 + \beta_2(X_{2t} + 0.2X_{3t}) + u_t$$

令 $X_t = X_{2t} + 0.2X_{3t}$ （这是一个已知的新变量，因为我们知道 X_{2t} 和 X_{3t} 的数据，也知道系数0.2），则：

$$Y_t = \beta_1 + \beta_2 X_t + u_t \quad (4.25)$$

发生了什么？原来有3个参数要估计 $(\beta_1, \beta_2, \beta_3)$ ，现在只剩2个了 (β_1, β_2) ，而且解释变量从2个合并成了1个！共线性问题直接消失了。

估计出 $\hat{\beta}_2$ 之后， $\hat{\beta}_3 = 0.2\hat{\beta}_2$ 也就自然得到了。

直觉比喻：本来你要同时猜两个密码，它们互相关联导致你猜不准。现在有人告诉你第二个密码是第一个密码的0.2倍，你只需要猜一个就行了，问题大大简化。

1.5 方法5：横截面数据与时序数据并用

核心思路：这是方法4（先验信息法）的一个变种。当我们无法直接获得先验信息时，可以用另一种数据来“替我们”估计部分参数。

完整推导——以中国家用轿车需求为例：

设定模型：

$$\ln Y_t = \beta_1 + \beta_2 \ln P_t + \beta_3 \ln I_t + u_t \quad (4.26)$$

- Y_t ：轿车销售量
- P_t ：平均价格
- I_t ：消费者收入
- β_2 ：价格弹性（价格变化1%，需求变化百分之几）
- β_3 ：收入弹性（收入变化1%，需求变化百分之几）

问题：在时间序列数据中，价格 P_t 和收入 I_t 通常高度相关（两者都随时间持续增长），导致 β_2 和 β_3 估计不准。

托宾的解决办法，分三步走：

第①步：用横截面数据（比如城镇/农村住户调查数据）估计收入弹性 β_3 。横截面数据是在同一时间点上、不同家庭的数据，此时各家庭的收入差异大但价格基本相同，所以不会受价格和收入共线性的困扰。设估计结果为 $\hat{\beta}_3^*$ 。

第②步：将 $\hat{\beta}_3^*$ 代入原时间序列模型。将式(4.26)改写：

$$\ln Y_t - \hat{\beta}_3^* \ln I_t = \beta_1 + \beta_2 \ln P_t + u_t$$

令 $Y_t^* = \ln Y_t - \hat{\beta}_3^* \ln I_t$ ，则：

$$Y_t^* = \beta_1 + \beta_2 \ln P_t + u_t \quad (4.27)$$

第③步：现在只需要用时间序列数据估计一元回归(4.27)，得到 $\hat{\beta}_2$ （价格弹性）。

发生了什么？原来二元回归中的共线性问题，被拆成了两步解决：横截面估计一个参数，时间序列估计另一个参数。

□**关键假设：**收入弹性的横截面估计 $\hat{\beta}_3^*$ 和从纯粹时间序列分析中得到的估计是一样的。如果这个假设不成立（比如横截面上的收入效应和随时间变化的收入效应不同），结果就会有偏差。

1.6 方法6：变量变换

有时不改变模型形式，只对变量本身做变换，也能降低共线性。常用的变换方式有四种：

（1）计算相对指标

原来是总量指标（如GDP总量、消费总量），改为人均指标（人均GDP、人均消费）或结构相对数（消费占GDP的比重）。经过这样处理，原来同趋势增长的总量变成了相对稳定的比率，共线性可能降低。

（2）将名义数据转换为实际数据

名义数据包含价格变动和物量变动双重影响。剔除价格影响后的实际数据只反映物量变化，更可能揭示变量之间真实的数量关系，从而降低共线性。

（3）将小类指标合并成大类指标

例如，工业增加值和建筑业增加值通常高度相关（因为它们都受宏观经济景气影响），同时引入模型会产生严重共线性。将它们合并为“第二产业增加值”，用一个变量代替两个，共线性自然消除。

（4）将总量指标进行对数变换

原来的线性模型 $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$ ，对变量取对数后变成双对数模型 $\ln Y = \beta_0 + \beta_1 \ln X_1 + \beta_2 \ln X_2 + u$ ，此时系数的含义从“X变化1个单位，Y变化多少”变成“X变化1%，Y变化百分之几”。增长率之间的关系往往比水平值之间的关系更独立，共线性可能降低。

□**注意：**变量变换只是一种尝试性方法，有时效果很好，有时可能没有效果。不能保证每次都成功。

2 二、逐步回归法

2.1 核心思路

逐步回归法的想法很朴素：既然多个变量一起放进去会共线性，那我就一个一个往里加，每加一个都检查它是否“捣乱”。

2.2 具体步骤（逐步拆解）

步骤1：用被解释变量 Y 对每一个候选解释变量 $X_1, X_2, \dots, X_k$ 分别做简单回归（一元回归），一共做 k 个回归。

步骤2： 比较这 k 个回归的结果，选出对 Y 贡献最大的那个解释变量（看哪个回归的 $\bar{R}^2$ 最大）。把这个变量作为“基础变量”，它所对应的回归方程作为“基础方程”。

步骤3： 在基础方程的基础上，逐个引入其余的解释变量。每次引入一个新变量后，检查以下三个指标的变化：

表 1: 逐步回归中引入新变量后的判断准则

情形	$\bar{R}^2$	F 检验	其他原有变量的 t 检验	判断
①	改善了	通过	仍然显著	✓ 保留该变量
②	没改善	没改善	没受影响	× 该变量多余
③	没改善	没改善	显著受影响（系数变化大或不再显著）	× 出现严重共线性

对情形③的详细解释： 为什么新变量进来后，原来显著的变量突然不显著了？因为新变量和原来的某个变量高度相关（共线性！），它们“争抢”解释力，导致系数估计变得不稳定。这时应该把新变量剔除。

步骤4： 重复步骤3，直到所有候选变量都尝试过。最终保留在模型中的变量，既对 Y 有重要解释贡献，彼此之间又没有严重共线性。

2.3 优点与局限

优点： 最后保留的变量是统计上显著的、彼此间共线性不明显的，模型简洁有效。

□局限： 逐步回归可能删除了重要的相关变量，导致**设定偏误**。这就像医生在排除干扰因素时，不小心把真正的病因也排除了，治标不治本。

3 三、岭回归法

这是本节最重要的数学内容。前面几种方法都是“经验方法”，逻辑上比较直观；岭回归法则需要对数学公式进行严谨推导。

3.1 1. 岭回归的含义——为什么需要它？

问题回顾： 当解释变量之间存在多重共线性时，矩阵 $X'X$ 接近奇异（即行列式 $|X'X| \approx 0$ ）。我们知道OLS估计量为：

$$\hat{\beta} = (X'X)^{-1}X'Y$$

而 $\hat{\beta}$ 的方差-协方差矩阵为：

$$\text{Var}(\hat{\beta}) = \sigma^2(X'X)^{-1}$$

关键推理链条（无跳步）：

① $|X'X| \approx 0$ （因为多重共线性使 $X'X$ 接近奇异）

② $(X'X)^{-1}$ 中的元素会变得非常大（因为逆矩阵的元素涉及 $1/|X'X|$ 的运算，分母很小，值就很大）

③ $\text{Var}(\hat{\beta}) = \sigma^2(X'X)^{-1}$ 中的元素因此也非常大

④ 方差很大 $\rightarrow$ 标准误很大 $\rightarrow$ t统计量很小 $\rightarrow$ 系数不显著

这就是多重共线性导致OLS估计“不稳定”的数学根源！

岭回归的核心思想：既然问题出在 $X'X$ 接近奇异，那我就人为地给 $X'X$ 加上一个正常数对角矩阵 kI ($k > 0$)，使得 $|X'X + kI|$ 远离0。

直觉比喻：想象一个薄薄的冰面 ($X'X$)，你站在上面随时可能裂开（行列式接近0）。现在在冰面上铺一层木板 (kI)，冰面变厚了 ($X'X + kI$)，承重能力增强了（行列式远离0），你就安全了。

3.1.1 岭回归估计量的定义

$$\hat{\beta}(k) = (X'X + kI)^{-1}X'Y \quad (4.28)$$

其中：

- $\hat{\beta}(k)$ ：称为 β 的岭回归估计量（ridge estimate）
- k ：岭回归参数，也叫岭参数或偏倚参数， $k > 0$
- I ：单位矩阵（对角线上全是1，其余全是0的方阵）
- kI ：对角矩阵，对角线上全是 k ，其余全是0

极端情况的理解：

- 当 $k = 0$ 时： $\hat{\beta}(0) = (X'X)^{-1}X'Y = \hat{\beta}$ ，岭回归退化为普通OLS估计
- 当 k 很小时： $\hat{\beta}(k)$ 接近OLS估计，但可能仍然不稳定
- 当 k 逐渐增大时： $X'X + kI$ 越来越远离奇异， $\hat{\beta}(k)$ 趋于稳定
- 当 $k \rightarrow \infty$ 时： $(X'X + kI)^{-1} \approx (kI)^{-1} = \frac{1}{k}I$ ， $\hat{\beta}(k) \rightarrow 0$ ，所有系数都被压缩到0

所以，选择合适的 k 值是岭回归的关键： k 太小没效果， k 太大系数全被压没了。

3.2 2. 岭回归估计的性质（极其详细的推导）

3.2.1 性质1：岭回归的参数估计是回归参数的有偏估计

目标：证明 $E[\hat{\beta}(k)] \neq \beta$ （当 $k \neq 0$ 时）

推导（无跳步）：

$$E[\hat{\beta}(k)] = E[(X'X + kI)^{-1}X'Y]$$

这里, $(X'X + kI)^{-1}$ 和 X' 都是常数矩阵 (因为 X 被假定为固定), 只有 Y 是随机的。根据期望的线性性质, 常数矩阵可以提到期望符号外面:

$$= (X'X + kI)^{-1}X' \cdot E[Y]$$

现在关键是 $E[Y]$ 等于什么。由真实模型 $Y = X\beta + u$, 且 $E(u) = 0$, 所以:

$$E[Y] = E[X\beta + u] = X\beta + E(u) = X\beta + 0 = X\beta$$

代入回去:

$$= (X'X + kI)^{-1}X' \cdot X\beta = (X'X + kI)^{-1}(X'X)\beta \quad (4.29)$$

分析这个结果:

- 当 $k = 0$ 时: $(X'X + 0 \cdot I)^{-1}(X'X) = (X'X)^{-1}(X'X) = I$, 所以 $E[\hat{\beta}(0)] = I\beta = \beta$ 。
✓ 无偏!
- 当 $k \neq 0$ 时: $(X'X + kI)^{-1} \neq (X'X)^{-1}$, 所以 $(X'X + kI)^{-1}(X'X) \neq I$, 从而 $E[\hat{\beta}(k)] \neq \beta$ 。× 有偏!

有偏性的直觉理解: 岭回归为了获得更稳定的估计 (减小方差), 付出了代价——引入了偏差。这就像射击时, 你宁可枪口稍微偏一点但稳定性很高 (每次都打在同一个地方), 也不愿枪口对准靶心但弹着点到处散开。

3.2.2 性质2: $\hat{\beta}(k)$ 是最小二乘估计的一个线性变换

推导:

已知OLS估计量 $\hat{\beta} = (X'X)^{-1}X'Y$ 。

岭估计量 $\hat{\beta}(k) = (X'X + kI)^{-1}X'Y$ 。

我们想把 $\hat{\beta}(k)$ 表示成 $\hat{\beta}$ 的线性函数:

$$\hat{\beta}(k) = (X'X + kI)^{-1}X'Y$$

注意 $X'Y = X'X \cdot (X'X)^{-1}X'Y = X'X \cdot \hat{\beta}$ (因为 $\hat{\beta} = (X'X)^{-1}X'Y$, 两边左乘 $X'X$ 即得)。

代入:

$$\hat{\beta}(k) = (X'X + kI)^{-1}(X'X)\hat{\beta}$$

记 $W = (X'X + kI)^{-1}(X'X)$, 则 $\hat{\beta}(k) = W\hat{\beta}$ 。

因为 W 是常数矩阵 (仅依赖于 X 和 k), 所以 $\hat{\beta}(k)$ 是 $\hat{\beta}$ 的线性变换。

同时, 由于 $\hat{\beta}$ 本身是 Y 的线性函数, $\hat{\beta}(k)$ 也是 Y 的线性函数。

3.2.3 性质3：岭回归估计量的方差比OLS估计量的方差小

目标：证明 $\text{Var}(\hat{\beta}(k))$ 比 $\text{Var}(\hat{\beta})$ 小

推导（无跳步）：

由性质2， $\hat{\beta}(k) - E[\hat{\beta}(k)] = W(\hat{\beta} - \beta)$ （此处为简化说明，严格推导涉及偏倚项，但我们关注方差部分）。

更直接地，我们从定义出发：

$$\begin{aligned}\hat{\beta}(k) &= (X'X + kI)^{-1}X'Y = (X'X + kI)^{-1}X'(X\beta + u) \\ &= (X'X + kI)^{-1}X'X\beta + (X'X + kI)^{-1}X'u\end{aligned}$$

第一项是常数（因为 X 和 β 固定），第二项含有随机项 u 。所以 $\hat{\beta}(k)$ 的波动完全来自第二项。

$$\text{Var}(\hat{\beta}(k)) = \text{Var}[(X'X + kI)^{-1}X'u]$$

因为 $(X'X + kI)^{-1}X'$ 是常数矩阵，根据 $\text{Var}(Au) = A\text{Var}(u)A'$ ：

$$\begin{aligned}&= (X'X + kI)^{-1}X' \cdot \sigma^2 I \cdot X(X'X + kI)^{-1} \\ &= \sigma^2 (X'X + kI)^{-1}X'X(X'X + kI)^{-1}\end{aligned}$$

对比OLS的方差： $\text{Var}(\hat{\beta}) = \sigma^2(X'X)^{-1}$

为什么岭回归方差更小？直觉解释：

$(X'X + kI)$ 的特征值比 $X'X$ 的特征值大（每个特征值都加了 k ）。矩阵逆的特征值是原特征值的倒数，所以 $(X'X + kI)^{-1}$ 的特征值比 $(X'X)^{-1}$ 的特征值小。方差-协方差矩阵的“总大小”（用迹或行列式衡量）因此减小了。

简单比喻：OLS方差像是站在一个很窄的柱子上（不稳定，晃动大）；岭回归给柱子加宽了底座（加了 kI ），站上去更稳了（方差小了），但站的位置偏了（有偏了）。

3.3 3. 岭回归参数 k 的选择

核心矛盾： k 越大 $\rightarrow$ 偏倚越大、方差越小； k 越小 $\rightarrow$ 偏倚越小、方差越大。

用什么准则来权衡？最小均方误差（MSE）原则。

均方误差的定义：

$$\text{MSE}(\hat{\beta}(k)) = E[\hat{\beta}(k) - \beta][\hat{\beta}(k) - \beta]' = \text{方差} + \text{偏倚}^2$$

即： $\text{MSE} = \text{方差部分} + \text{偏倚的平方部分}$ 。

我们要找使 $\text{MSE}(\hat{\beta}(k))$ 达到最小的 k^* 。

问题：最优 k^* 依赖于未知参数 β 和 σ^2 ，所以理论上最优的 k 是无法直接计算的。实际中必须通过样本数据来确定。

常用方法：

表 2: 岭回归参数 k 的选择方法

方法	基本思路
岭迹法	画出 $\hat{\beta}_j(k)$ 随 k 变化的曲线（岭迹图），选择系数开始趋于稳定时的 k
方差扩大因子法	选择使所有VIF都降到合理范围（如小于10）的 k
残差平方和法	在残差平方和不过分增大的前提下，选尽可能大的 k

逐步搜索法的实际操作：

1. 从很小的 k 开始（如 $k = 0.01$ ）
2. 逐渐增大 k （如 0.02, 0.05, 0.1, 0.2, 0.5, 1, 2, ...）
3. 每次计算 $\hat{\beta}(k)$ ，观察系数值的变化
4. 当系数值开始趋于稳定时，选择该 k 值

□**局限：** 逐步搜索法确定 k 值缺乏严密的理论依据，具有一定的主观性，是一种将定性分析与定量分析相结合的方法。

拓展：与岭回归相似的其他方法

表 3: 与岭回归相似的其他方法

方法	核心特点
Lasso回归	用 $\lambda \sum \beta_j $ 替代岭回归的 $\lambda \sum \beta_j^2$ ，可以将某些系数压缩到恰好0（自动变量选择）
适应性Lasso回归	对Lasso的惩罚权重做自适应调整，改善Lasso的某些理论缺陷
主成分分析	将原来的共线性变量转换为少数几个互不相关的主成分，用主成分做回归
偏最小二乘回归	类似主成分但兼顾与因变量的相关性，提取成分时同时考虑自变量和因变量

总结：整篇讲解的逻辑链条

1. 诊断出共线性后怎么办？→ 六种经验方法（剔除变量、增大样本、差分法、先验信息、数据并用、变量变换）+ 逐步回归法 + 岭回归法
2. 经验方法的共同思路 → 减少需要估计的参数个数，或降低变量之间的相关性
3. 逐步回归 → 一个个变量试探，保留有用的、剔除“捣乱”的

4. 岭回归 → 核心数学：给 $X'X$ 加 kI 使其远离奇异，代价是估计量从无偏变为有偏，但方差大幅减小；用MSE准则权衡偏倚与方差
5. 岭参数 k 的选择 → 没有公认最优方法，岭迹法、VIF法、逐步搜索法都是实用但带主观性的方法